




Projet DATAImmo

Florian Mounier



Laplace Immo



La première étape du projet DATAImmo est de structurer une base de données immobilière robuste et conforme (notamment RGPD), afin d'établir un socle analytique précis permettant ultérieurement la **prévision fiable du prix de vente des biens immobiliers.**

Nouvel axe stratégique : prévoir le prix de vente des biens immobiliers

Se démarquer de la
concurrence

Capitaliser sur les
données collectées

Sauvegarde en 3-2-1 et RGPD respectée



Données fournies par l'INSEE
et data.gouv

Suppression de toutes
informations sensibles

Trouver des données fiables à nettoyer et ordonner

Open Data : Demandes de valeurs foncières

INSEE : recensements de la population

data.gouv : données géographiques complètes
(régions, communes, départements...)

Selectionner et définir les données importantes

Open Data DVF

SIGNIFICATION	TYPE	LONGUEUR	NATURE	REGLE DE GESTION	REGLE DE CALCUL
Identification du bien	Varchar	50	Concaténer	Ne doit pas être nul	Code_departement&Code_commune&Prefixe_de_section&Section&No_plan&1er_lot
Identification de la vente	Varchar	50	Concaténer	Ne doit pas être nul	date_mutation&Code_departement&Code_commune&Prefixe_de_section&Section&No_plan&1er_lot
Dates des transferts de propriété	Date	NC	Elémentaire	format aaaa-mm-jj	
Valeurs des biens	Float	NC	Elémentaire	Ne doit pas être nul	
Numéro des rues	Integer	NC	Elémentaire		
Complément numéro de voie	Varchar	1	Elémentaire		
Plusieurs valeurs (rue, avenue, chemin, etc.)	Varchar	4	Elémentaire		
Nom de la rue	Varchar	50	Elémentaire		
Identifiant unique de chaque commune	Varchar	6	Concaténer	Ne doit pas être nul	Code_departement&Code_commune
Plusieurs valeurs (Appartement, Maison...)	Varchar	50	Elémentaire	Ne doit pas être nul	
Surface Carrez des biens	Float	NC	Elémentaire	Ne doit pas être nul	
Somme de la surface réelle du local et de la surface des dépendances	Integer	NC	Elémentaire		
Nombre de pièces des biens	Integer	NC	Elémentaire		


INSEE

CODE	SIGNIFICATION	TYPE	LONGUEUR	NATURE	REGLE DE GESTION	REGLE DE CALCUL
CODDEP_CODCOM	Identification de la commune	Varchar	6	Concaténer	Ne doit pas être nul	CODDEP&CODCOM
PMUN	Population municipale	Integer	NC	Elémentaire	Ne doit pas être nul	
PCAP	Population comptée à part	Integer	NC	Elémentaire	Ne doit pas être nul	


data.gouv

CODE	SIGNIFICATION	TYPE	LONGUEUR	NATURE	REGLE DE GESTION
reg_code	identifiant de la region	Varchar	6	Elémentaire	Ne doit pas être nul
reg_nom	Nom des régions	Varchar	50	Elémentaire	Ne doit pas être nul
com_nom_maj	Nom des communes	Varchar	50	Elémentaire	Ne doit pas être nul
dep_code	Numéros des départements	Varchar	3	Elémentaire	Ne doit pas être nul
dep_nom	Nom des départements	Varchar	50	Elémentaire	Ne doit pas être nul
com_code	identifiant commune	Varchar	6	Elémentaire	Ne doit pas être nul
dep_id	identifiant département	Varchar	4	Elémentaire	Ne doit pas être nul

Créer et mettre en relation les tables de données



Charger les données dans les tables



	AZ_id_bien	AZ_id_commune	I23_no_voie	AZ_btq	AZ_type_voie
1	01103A30212	01103		347	rue
2	06004CP186132	06004		4	bd
3	06088L516999	06088		20	b rue
4	06123A0348242	06123		550	rte
5	13005AW224218	13005		9300	res
6	13028AB692	13028		27	rue
7	1320843C21112	13208		360	av
8	13212873A971080	13212		5076	f parc
9	14338AC181155	14338		1194	rue
10	14366BH9332	14366		30	all
11	17300C21386	17300		11	rue
12	25056M21436	25056		13	rue
13	29232K128305	29232		1	rue
14	29260B01993	29260		2	rue
15	31555834AB1419	31555		5	av
16	33063K2598	33063		15	rue
17	33063HD20312	33063		176	rue

	AZ_id_vente	AZ_id_bien	AZ_date_vente	I23_valeur_fonciere
1	43998751160D1853	75116D1853	2020-06-16	900000,00
2	4385991174X16322	91174X16322	2020-01-29	8600000,00
3	4385275107AK34100	75107AK34100	2020-01-22	8577713,00
4	4386875117CO10015	75117CO10015	2020-02-07	7620000,00
5	4388075106AU14104	75106AU14104	2020-02-19	7600000,00
6	4393875101AZ8679	75101AZ8679	2020-04-17	7535000,00
7	4383675116DV465	75116DV465	2020-01-06	7420000,00
8	4391675116CN2411	75116CN2411	2020-03-26	7200000,00
9	4384475101BC672	75101BC672	2020-01-14	7050000,00
10	4395175101AT4181	75101AT4181	2020-04-30	6600000,00
11	4398675116FA11018	75116FA11018	2020-06-04	6500000,00
12	4388775103AT93323	75103AT93323	2020-02-26	6454000,00
13	4389675107BL4512	75107BL4512	2020-03-06	6000000,00
14	4388975101AV282	75101AV282	2020-02-28	5600000,00
15	4392775116DG812	75116DG812	2020-04-06	5550000,00
16	4391475107AH152024	75107AH152024	2020-03-24	5500000,00
17	4385475107AP1911	75107AP1911	2020-01-24	5054500,00
18	4388275116FA60408	75116FA60408	2020-02-21	4657000,00

	AZ_id_commune	AZ_id_departement	AZ_nom_commune	I23_population_mur
1	01001	d001	l'abergement-clémenciat	
2	01002	d001	l'abergement-de-varey	
3	01003	d001	amareins	
4	01004	d001	amberieu-en-bugey	
5	01005	d001	amberieu-en-dombes	
6	01006	d001	ambléon	
7	01007	d001	ambronay	
8	01008	d001	ambutrix	
9	01009	d001	andert-et-condon	
10	01010	d001	anglefort	
11	01011	d001	apremont	
12	01012	d001	aranc	
13	01013	d001	arandas	
14	01014	d001	arben	
15	01015	d001	arignieu	
16	01016	d001	arignieu	
17	01017	d001	argis	
18	01018	d001	arlot	

	AZ_id_departement	I23_id_region	AZ_code_departement	AZ_nom_departement
1	d001	84	1	ain
2	d002	32	2	aisne
3	d003	84	3	allier
4	d004	93	4	alpes-de-haute-p
5	d005	93	5	hautes-alpes
6	d006	93	6	alpes-maritimes
7	d007	84	7	ardèche
8	d008	44	8	ardennes
9	d009	76	9	ariège
10	d010	44	10	aube
11	d011	76	11	aude
12	d012	76	12	aveyron
13	d013	93	13	bouches-du-rhon
14	d014	28	14	calvados
15	d015	84	15	cantal
16	d016	75	16	charente
17	d017	75	17	charente-maritime
18	d018	24	18	cher

	I23_id_region	AZ_nom_region
1	11	ile-de-france
2	24	centre-val de loire
3	27	bourgogne-franche-comte
4	28	normandie
5	32	hauts-de-france
6	44	grand est
7	52	pays de la loire
8	53	bretagne
9	75	nouvelle-aquitaine
10	76	occitanie
11	84	auvergne-rhone-alpes
12	93	provence-alpes-cote d'azur
13	94	corse
14	0	collectivités d'outre-mer
15	1	guadeloupe
16	2	martinique
17	3	guyane
18	4	la reunion



Requêtes SQL et résultats

Nombre total d'appartements vendus au 1er semestre 2020

```
SELECT COUNT(*)  
FROM vente v  
LEFT JOIN bien b ON v.id_bien = b.id_bien  
WHERE b.type_local = "appartement"  
AND v.date_vente BETWEEN "2020-01-01" AND "2020-06-30"
```

31 362

Nombre de ventes d'appartement par région pour le 1er semestre 2020

```
SELECT r.nom_region, COUNT(v.id_vente ) AS nombre_ventes
FROM vente v
LEFT JOIN bien b ON v.id_bien = b.id_bien
LEFT JOIN commune c ON b.id_commune = c.id_commune
LEFT JOIN departement d ON d.id_departement = c.id_departement
LEFT JOIN region r ON d.id_region = r.id_region
WHERE b.type_local = "appartement"
AND v.date_vente BETWEEN "2020-01-01" AND "2020-06-30"
GROUP BY r.nom_region
ORDER BY nombre_ventes DESC
```

	AZ nom_region	123 nombre_ventes
1	ile-de-france	13989
2	provence-alpes-cote d'azur	3645
3	auvergne-rhone-alpes	3253
4	nouvelle-aquitaine	1931
5	occitanie	1640
6	pays de la loire	1357
7	hauts-de-france	1252
8	grand est	984
9	bretagne	983
10	normandie	861
11	centre-val de loire	695
12	bourgogne-franche-comte	376
13	corse	222
14	martinique	94
15	la reunion	44
16	guyane	34
17	guadeloupe	2

Proportion des ventes d'appartements par le nombre de pièces

```
SELECT b.nombre_pieces, ROUND((COUNT(v.id_vente)*100.0/SUM(COUNT(v.id_vente)) OVER()),2) AS proportion_ventes
FROM vente v
INNER JOIN bien b ON v.id_bien = b.id_bien
WHERE b.type_local = "appartement"
GROUP BY b.nombre_pieces
ORDER BY proportion_ventes DESC
```

	123 nombre_pieces	123 proportion_ventes
1	2	31,16
2	3	28,59
3	1	21,48
4	4	14,21
5	5	3,55
6	6	0,65
7	7	0,17
8	0	0,1
9	8	0,05
10	9	0,03
11	10	0,01
12	11	0

Liste des 10 départements où le prix du mètre carré est le plus élevé

```
SELECT d.nom_departement, ROUND(SUM(v.valeur_fonciere) / SUM(b.surface_carrez),2) AS prix_m2
FROM vente v
LEFT JOIN bien b ON v.id_bien = b.id_bien
LEFT JOIN commune c ON b.id_commune = c.id_commune
LEFT JOIN departement d ON c.id_departement = d.id_departement
GROUP BY d.nom_departement
ORDER BY prix_m2 DESC
LIMIT 10
```

	AZ nom_departement	123 prix_m2
1	paris	12015,62
2	hauts-de-seine	7296,04
3	val-de-marne	4871,26
4	alpes-maritimes	4627,32
5	haute-savoie	4195,68
6	seine-saint-denis	4108,83
7	yvelines	4030,6
8	rhone	3920,37
9	corse-du-sud	3795,52
10	gironde	3597,35

Prix moyen du mètre carré d'une maison en Île-de-France

```
SELECT ROUND(SUM(v.valeur_fonciere) / SUM(b.surface_carrez),2) AS prix_m2_moyen_IDF
FROM vente v
LEFT JOIN bien b ON v.id_bien = b.id_bien
LEFT JOIN commune c ON b.id_commune = c.id_commune
LEFT JOIN departement d ON d.id_departement = c.id_departement
LEFT JOIN region r ON d.id_region = r.id_region
WHERE b.type_local = "maison" AND r.nom_region = "ile-de-france"
```

3 692,59 €/m²

Liste des 10 appartements les plus chers avec la région et le nombre de mètres carrés

```
SELECT b.id_bien, r.nom_region, b.surface_carrez, v.valeur_fonciere
FROM vente v
LEFT JOIN bien b ON v.id_bien = b.id_bien
LEFT JOIN commune c ON b.id_commune = c.id_commune
LEFT JOIN departement d ON d.id_departement = c.id_departement
LEFT JOIN region r ON d.id_region = r.id_region
WHERE b.type_local = "appartement"
ORDER BY ROUND(v.valeur_fonciere,2) DESC
LIMIT 10
```

	AZ id_bien	AZ nom_region	123 surface_carrez	123 valeur_fonciere
1	75116DD1853	ile-de-france	9,10	9000000,00
2	91174AX16322	ile-de-france	64,00	8600000,00
3	75107AK34100	ile-de-france	20,55	8577713,00
4	75117CO10015	ile-de-france	42,77	7620000,00
5	75106AU14104	ile-de-france	253,30	7600000,00
6	75101AZ8679	ile-de-france	139,90	7535000,00
7	75116DV465	ile-de-france	360,95	7420000,00
8	75116CN2411	ile-de-france	595,00	7200000,00
9	75101BC672	ile-de-france	122,56	7050000,00
10	75101AT4181	ile-de-france	79,38	6600000,00

Taux d'évolution du nombre de ventes entre le premier et le second trimestre de 2020

```
WITH ventes_t1 AS (  
  SELECT COUNT(*) AS total_t1  
  FROM vente v  
  WHERE v.date_vente BETWEEN "2020-01-01" AND "2020-03-31"),  
ventes_t2 AS (  
  SELECT COUNT(*) AS total_t2  
  FROM vente v  
  WHERE v.date_vente BETWEEN "2020-04-01" AND "2020-06-30")  
SELECT t1.total_t1, t2.total_t2, ROUND(100.0*(t2.total_t2-t1.total_t1)/t1.total_t1,2) AS taux_evolution  
FROM ventes_t1 t1, ventes_t2 t2
```

	123 total_t1	123 total_t2	123 taux_evolution
1	16769	17382	3,66

Le classement des régions par rapport au prix au mètre carré des appartement de plus de 4 pièces

```
SELECT r.nom_region, ROUND(SUM(v.valeur_fonciere) / SUM(b.surface_carrez),2) AS prix_m2
FROM vente v
LEFT JOIN bien b ON v.id_bien = b.id_bien
LEFT JOIN commune c ON b.id_commune = c.id_commune
LEFT JOIN departement d ON d.id_departement = c.id_departement
LEFT JOIN region r ON d.id_region = r.id_region
WHERE b.type_local = "appartement" AND b.nombre_pieces > 4
GROUP BY r.nom_region
ORDER BY prix_m2 DESC
```

	A2 nom_region	123 prix_m2
1	ile-de-france	9227,03
2	la reunion	3484,52
3	corse	3458,45
4	provence-alpes-cote d'azur	3179,85
5	auvergne-rhone-alpes	2943,1
6	nouvelle-aquitaine	2556
7	pays de la loire	2506,48
8	bretagne	2336,68
9	hauts-de-france	2289,74
10	occitanie	2192,33
11	normandie	2129,83
12	grand est	1481,82
13	centre-val de loire	1466,03
14	bourgogne-franche-comte	1131,03
15	martinique	574,77

Liste des communes ayant eu au moins 50 ventes au 1er trimestre

```
SELECT c.nom_commune, COUNT(v.id_vente) AS nombre_ventes
FROM vente v
LEFT JOIN bien b ON v.id_bien = b.id_bien
LEFT JOIN commune c ON b.id_commune = c.id_commune
LEFT JOIN departement d ON d.id_departement = c.id_departement
LEFT JOIN region r ON d.id_region = r.id_region
GROUP BY c.nom_commune
HAVING COUNT(v.id_vente) >= 50 AND v.date_vente BETWEEN "2020-01-01" AND "2020-03-31"
ORDER BY nombre_ventes DESC
```

paris 18e arrondissement	516
paris 17e arrondissement	470
nice	393
paris 19e arrondissement	267
paris 12e arrondissement	254
paris 9e arrondissement	208
toulouse	188
toulon	162
courbevoie	163
paris 3e arrondissement	161
antibes	147
vincennes	141
paris 8e arrondissement	139
paris 6e arrondissement	139
montrouil	138
paris 7e arrondissement	135
saint-etienne	123
saint-maur-des-fosses	116
hyeres	114
le havre	113
ajaccio	104
boulogne-billancourt	99
orleans	97
troyes	93

lyon 9e arrondissement	93
menton	91
lyon 3e arrondissement	89
montrouge	85
asnières-sur-seine	85
issy-les-moulineaux	84
nogent-sur-marne	82
marseille 8e arrondissement	82
marseille 4e arrondissement	81
chartres	80
merignac	79
le perreux-sur-marne	78
marseille 1er arrondissement	75
talence	74
alfortville	73
saint-malo	72
saint-mande	69
marseille 9e arrondissement	67
brest	67
agde	67
le cannet	66
fontenay-sous-bois	66
creteil	65
charenton-le-pont	65

leucate	64
la ciotat	64
valence	63
sartrouville	63
fresnes	63
besancon	62
montpellier	60
saint-ouen	59
amiens	58
compiègne	55
arcachon	55
pontoise	54
villejuif	53
etampes	53
corbeil-essonne	53
chelles	53
roquebrune-cap-martin	52
clamart	52
evry	51
dax	51
caluire-et-cuire	51
vanves	50
bourges	50

Différence en pourcentage du prix au mètre carré entre un appartement de 2 pièces et un appartement de 3 pièces

```
WITH appart_2p AS (  
  SELECT ROUND(SUM(v.valeur_fonciere) / SUM(b.surface_carrez),2) AS prix_m2  
  FROM vente v  
  LEFT JOIN bien b ON v.id_bien = b.id_bien  
  WHERE b.type_local = "appartement"  
  AND b.nombre_pieces = 2),  
  appart_3p AS (  
  SELECT ROUND(SUM(v.valeur_fonciere) / SUM(b.surface_carrez),2) AS prix_m2  
  FROM vente v  
  LEFT JOIN bien b ON v.id_bien = b.id_bien  
  WHERE b.type_local = "appartement"  
  AND b.nombre_pieces = 3)  
  SELECT ROUND((appart_3p.prix_m2-appart_2p.prix_m2)/appart_2p.prix_m2*100,0) AS difference  
  FROM appart_2p, appart_3p
```

-13%

Les moyennes de valeurs foncières pour le top 3 des communes des départements 6, 13, 33, 59 et 69


```
WITH ClassementCommunes AS (  
  SELECT c.nom_commune, d.nom_departement,  
    ROUND(AVG(v.valeur_fonciere), 0) AS moyenne_fonciere,  
    RANK() OVER (PARTITION BY d.code_departement  
      ORDER BY AVG(v.valeur_fonciere) DESC) AS rang_commune  
  FROM vente v  
  INNER JOIN bien b ON v.id_bien = b.id_bien  
  INNER JOIN commune c ON b.id_commune = c.id_commune  
  INNER JOIN departement d ON d.id_departement = c.id_departement  
  WHERE d.code_departement IN ('6', '13', '33', '59', '69')  
  GROUP BY c.nom_commune, d.nom_departement, d.code_departement)  
SELECT nom_departement, nom_commune, moyenne_fonciere  
FROM ClassementCommunes  
WHERE rang_commune <= 3  
ORDER BY nom_departement ASC, moyenne_fonciere DESC
```

	AZ nom_departement	AZ nom_commune	123 moyenne_fonciere
1	alpes-maritimes	saint-jean-cap-ferrat	968 750
2	alpes-maritimes	eze	655 000
3	alpes-maritimes	mouans-sartoux	476 898
4	bouches-du-rhone	gignac-la-nerthe	330 000
5	bouches-du-rhone	saint-savournin	314 425
6	bouches-du-rhone	cassis	313 417
7	gironde	lege-cap-ferret	549 501
8	gironde	vayres	335 000
9	gironde	arcachon	307 436
10	nord	bersee	433 202
11	nord	cysoing	408 550
12	nord	halluin	322 250
13	rhone	ville-sur-jarnioux	485 300
14	rhone	lyon 2e arrondissement	455 217
15	rhone	lyon 6e arrondissement	426 968

Les 20 communes avec le plus de transactions pour 1000 habitants pour les communes qui dépassent les 10 000 habitants

```
SELECT c.nom_commune, c.population_municipale,  
ROUND(COUNT(v.id_vente)*1000.0/c.population_municipale)  
AS transactions_pour_1000  
FROM vente v  
LEFT JOIN bien b ON v.id_bien = b.id_bien  
LEFT JOIN commune c ON b.id_commune = c.id_commune  
WHERE c.population_municipale > 10000 AND  
c.population_municipale IS NOT NULL  
GROUP BY c.nom_commune, c.population_municipale  
ORDER BY transactions_pour_1000 DESC  
LIMIT 20
```

	AZ nom_commune	123 population_municipale	123 transactions_pour_1000
1	paris 2e arrondissement	21 595	6
2	arcachon	11 630	5
3	la baule-escoublac	16 255	5
4	paris 1er arrondissement	15 917	5
5	paris 3e arrondissement	34 025	5
6	paris 4e arrondissement	29 131	4
7	paris 8e arrondissement	35 655	4
8	roquebrune-cap-martin	12 839	4
9	sanary-sur-mer	16 889	4
10	arpajon	11 355	3
11	avon	13 419	3
12	chantilly	10 950	3
13	enghien-les-bains	11 470	3
14	la londe-les-maures	10 641	3
15	lyon 1er arrondissement	29 641	3
16	menton	30 525	3
17	montevrain	13 517	3
18	paris 10e arrondissement	86 472	3
19	paris 11e arrondissement	145 208	3
20	paris 17e arrondissement	166 543	3



La première étape du projet DATAImmo est de structurer une base de données immobilière robuste et conforme (notamment RGPD), afin d'établir un socle analytique précis permettant ultérieurement la **prévision fiable du prix de vente des biens immobiliers.**