

✓ Etape 1 - Importation des librairies et chargement des fichiers

✓ 1.1 - Importation des librairies et paramétrage

```
#Importation de la librairie Pandas
import pandas as pd

#Importation de la librairie NumPy
import numpy as np

#Afficher toutes les colonnes d'un dataframe et monter le maximum de
pd.set_option('display.max_columns', None)
pd.set_option('display.max_rows', 100)
```

✓ 1.2 - Chargement des fichiers

```
#Connecter au Google Drive
from google.colab import drive
drive.mount('/content/drive')

#Importation des données FAO
df_fao_dispo = pd.read_csv('/content/drive/MyDrive/Colab Notebooks/D
df_fao_healthydiet = pd.read_csv('/content/drive/MyDrive/Colab Noteb
df_fao_PIB = pd.read_csv('/content/drive/MyDrive/Colab Notebooks/Dat
df_fao_population = pd.read_csv('/content/drive/MyDrive/Colab Notebo
df_fao_stability = pd.read_csv('/content/drive/MyDrive/Colab Noteboo

#importation des données de WBG
df_wbg_index = pd.read_csv('/content/drive/MyDrive/Colab Notebooks/D
df_wbg_temperature = pd.read_csv('/content/drive/MyDrive/Colab Noteb

#importation des données de CEPII
df_cepii_distance = pd.read_csv('/content/drive/MyDrive/Colab Notebo
df_cepii_langue = pd.read_csv('/content/drive/MyDrive/Colab Notebook
```

Drive already mounted at /content/drive; to attempt to forcibly remc

- ✓ Etape 2 - Analyse exploratoire des fichiers
- ✓ 2.1 - Analyse exploratoire df_fao_dispo
- ✓ 2.1.1 - Evalutation du dataset

```
#Caractéristiques
df_fao_dispo.info()
print("\n")
df_fao_dispo.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9662 entries, 0 to 9661
Data columns (total 15 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Code Domaine                         9662 non-null   object
1   Domaine                             9662 non-null   object
2   Code zone (M49)                     9662 non-null   int64
3   Zone                                9662 non-null   object
4   Code Élément                        9662 non-null   int64
5   Élément                             9662 non-null   object
6   Code Produit (FBS)                  9662 non-null   object
7   Produit                             9662 non-null   object
8   Code année                          9662 non-null   int64
9   Année                              9662 non-null   int64
10  Unité                               9662 non-null   object
11  Valeur                              9662 non-null   float64
12  Symbole                             9662 non-null   object
13  Description du Symbole               9662 non-null   object
14  Note                                0 non-null      float64
dtypes: float64(2), int64(4), object(9)
memory usage: 1.1+ MB
```

	Code Domaine	Domaine	Code zone (M49)	Zone	Code Élément	Éléme
count	9662	9662	9662.000000	9662	9662.000000	96
unique	1	1	NaN	179	NaN	
top	FBS	Bilans Alimentaires (2010-)	NaN	Afghanistan	NaN	Disponibil alimenta en quant ..

						(kg/person)
freq	9662	9662	NaN	56	NaN	24
mean	NaN	NaN	431.307390	NaN	4262.055682	Na
std	NaN	NaN	251.780133	NaN	2096.887250	Na
min	NaN	NaN	4.000000	NaN	645.000000	Na
25%	NaN	NaN	214.000000	NaN	645.000000	Na
50%	NaN	NaN	426.000000	NaN	5301.000000	Na
75%	NaN	NaN	643.000000	NaN	5611.000000	Na
max	NaN	NaN	894.000000	NaN	5611.000000	Na

#Premières lignes
df_fao_dispo.head()

	Code Domaine	Domaine	Code zone (M49)	Zone	Code Élément	Élément	Code Produit (FBS)
0	FBS	Bilans Alimentaires (2010-)	4	Afghanistan	5511	Production	S2734
1	FBS	Bilans Alimentaires (2010-)	4	Afghanistan	5611	Importations - quantité	S2734
2	FBS	Bilans Alimentaires (2010-)	4	Afghanistan	5301	Disponibilité intérieure	S2734
3	FBS	Bilans Alimentaires (2010-)	4	Afghanistan	645	Disponibilité alimentaire en quantité (kg/pers...	S2734
4	FBS	Bilans Alimentaires (2010-)	4	Afghanistan	5511	Production	S2734

```
#Dernières lignes
df_fao_dispo.tail()
```

	Code Domaine	Domaine	Code zone (M49)	Zone	Code Élément	Élément	Code Produit (FBS)
9657	FBS	Bilans Alimentaires (2010-)	716	Zimbabwe	645	Disponibilité alimentaire en quantité (kg/pers...	S2734
9658	FBS	Bilans Alimentaires (2010-)	716	Zimbabwe	5511	Production	S2734
9659	FBS	Bilans Alimentaires (2010-)	716	Zimbabwe	5611	Importations - quantité	S2734
9660	FBS	Bilans Alimentaires (2010-)	716	Zimbabwe	5301	Disponibilité intérieure	S2734
Bilan : 9661	FBS	Bilans Alimentaires	716	Zimbabwe	645	Disponibilité alimentaire ...	S2734

- Colonne "Note" vide (NaN) : à supprimer
- Pas de PK native
- Pas de NaN sur les autres colonnes
- 179 pays différents

✓ 2.1.2 - Nettoyage

```
#Suppression des colonnes superflues
df_fao_dispo_c = df_fao_dispo.drop(columns=['Code Domaine','Domaine
df_fao_dispo_c['Élément'] = df_fao_dispo_c['Élément'] + ' (' + df_f
df_fao_dispo_c.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9662 entries, 0 to 9661
Data columns (total 6 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Code zone (M49)       9662 non-null   int64
1   Zone                  9662 non-null   object
2   Élément               9662 non-null   object
3   Année                 9662 non-null   int64
4   Unité                 9662 non-null   object
5   Valeur                9662 non-null   float64
dtypes: float64(1), int64(2), object(3)
memory usage: 453.0+ KB
```

✓ 2.1.3 - Mise en forme

```
#Mise en forme pivot
```

```
df_fao_dispo_p = df_fao_dispo_c.pivot_table(index=['Zone','Code zone'], columns=['Année'], values=[
df_fao_dispo_p
```

Élément	Zone	Code zone (M49)	Année	Disponibilité alimentaire en quantité (kg/personne/an) (kg/personne)	Disponibilité intérieure (1000 t)	Imp
0	Afghanistan	4	2010	2.28	65.0	
1	Afghanistan	4	2011	1.91	56.0	
2	Afghanistan	4	2012	2.04	62.0	
3	Afghanistan	4	2013	2.10	67.0	
4	Afghanistan	4	2014	2.10	69.0	
...	...	...	...	...	...	
2420	Îles Salomon	90	2019	6.31	5.0	
2421	Îles Salomon	90	2020	7.29	5.0	
2422	Îles Salomon	90	2021	8.46	6.0	
2423	Îles Salomon	90	2022	8.72	7.0	
2424	Îles	90	2023	9.30	7.0	

```
#Mise en forme finale
```

```
df_fao_dispo_f = df_fao_dispo_p.rename(columns={'Zone': 'Pays', 'Code
colonne_a_deplacer = df_fao_dispo_f.pop('Dispo intérieure viande vc
df_fao_dispo_f.insert(6, 'Dispo intérieure viande volaille (1000 t)
df_fao_dispo_f.columns.name = None
df_fao_dispo_f = df_fao_dispo_f.dropna()
df_fao_dispo_f
```

	Pays	Code pays	Année	Dispo viande volaille (kg/personne/an)	Import viande volaille (1000 t)	Production viande volaille (1000 t)
0	Afghanistan	4	2010	2.28	39.0	28.0
1	Afghanistan	4	2011	1.91	51.0	26.0
2	Afghanistan	4	2012	2.04	22.0	25.0
3	Afghanistan	4	2013	2.10	48.0	26.0
4	Afghanistan	4	2014	2.10	43.0	25.0
...	...	...	...	...	...	...
2420	Îles Salomon	90	2019	6.31	4.0	0.0
2421	Îles Salomon	90	2020	7.29	5.0	0.0
2422	Îles Salomon	90	2021	8.46	6.0	0.0
2423	Îles Salomon	90	2022	8.72	7.0	0.0
2424	Îles	90	2023	8.20	7.0	0.0

```
#Caractéristiques
df_fao_dispo_f.info()
print("\n")
df_fao_dispo_f.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 2387 entries, 0 to 2424
Data columns (total 7 columns):
#   Column                                                                 Non-Null Count  Dtype
---  -
0   Pays                                                                    2387 non-null   object
1   Code pays                                                                2387 non-null   int64
2   Année                                                                    2387 non-null   int64
3   Dispo viande volaille (kg/personne/an)  2387 non-null   float64
4   Import viande volaille (1000 t)      2387 non-null   float64
5   Production viande volaille (1000 t)   2387 non-null   float64
6   Dispo intérieure viande volaille (1000 t) 2387 non-null   float64
dtypes: float64(4), int64(2), object(1)
memory usage: 149.2+ KB
```

	Pays	Code pays	Année	Dispo viande volaille (kg/personne/an)	Import viande volaille (1000 t)
count	2387	2387.000000	2387.000000	2387.000000	2387.000000
unique	176	NaN	NaN	NaN	NaN
top	Afghanistan	NaN	NaN	NaN	NaN
freq	14	NaN	NaN	NaN	NaN
mean	NaN	431.713867	2016.556347	22.274114	94.422287
std	NaN	252.986997	4.037605	17.538816	223.247605
min	NaN	4.000000	2010.000000	0.400000	0.000000
25%	NaN	214.000000	2013.000000	7.720000	3.000000
50%	NaN	426.000000	2017.000000	19.220000	18.000000

2.2 - Analyse exploratoire df_fao_healthydiet

2.2.1 - Evaluation du dataset

```
#Caractéristiques
df_fao_healthydiet.info()
print("\n")
df_fao_healthydiet.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1400 entries, 0 to 1399
Data columns (total 15 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Code Domaine                          1400 non-null   object
1   Domaine                              1400 non-null   object
2   Code zone (M49)                       1400 non-null   int64
3   Zone                                 1400 non-null   object
4   Code Élément                          1400 non-null   int64
5   Élément                              1400 non-null   object
6   Code Produit                          1400 non-null   int64
7   Produit                              1400 non-null   object
8   Code année                           1400 non-null   int64
9   Année                               1400 non-null   int64
10  Édition                              1400 non-null   object
11  Unité                                1400 non-null   object
12  Valeur                               1209 non-null   object
13  Symbole                              1400 non-null   object
14  Description du Symbole                1400 non-null   object
dtypes: int64(5), object(10)
memory usage: 164.2+ KB
```

	Code Domaine	Domaine	Code zone (M49)	Zone	Code Élément	Élément	Co Produit
count	1400	1400	1400.000000	1400	1400.0	1400	1400
unique	1	1	NaN	175	NaN	1	N
top	CAHD	Coût et abordabilité d'une alimentation saine\...	NaN	Afrique du Sud	NaN	Valeur	N
freq	1400	1400	NaN	8	NaN	1400	N
mean	NaN	NaN	419.497143	NaN	6132.0	NaN	7000
std	NaN	NaN	249.400617	NaN	0.0	NaN	0
min	NaN	NaN	8.000000	NaN	6132.0	NaN	7000

25%	NaN	NaN	196.000000	NaN	6132.0	NaN	7000
50%	NaN	NaN	417.000000	NaN	6132.0	NaN	7000
75%	NaN	NaN	643.000000	NaN	6132.0	NaN	7000
max	NaN	NaN	894.000000	NaN	6132.0	NaN	7000

#Premières lignes
df_fao_healthydiet.head()

	Code Domaine	Domaine	Code zone (M49)	Zone	Code Élément	Élément	Code Produit	Produit
0	CAHD	Coût et abordabilité d'une alimentation saine\...	710	Afrique du Sud	6132	Valeur	7006	Numb of peop unable afford health di
1	CAHD	Coût et abordabilité d'une alimentation saine\...	710	Afrique du Sud	6132	Valeur	7006	Numb of peop unable afford health di
2	CAHD	Coût et abordabilité d'une alimentation saine\...	710	Afrique du Sud	6132	Valeur	7006	Numb of peop unable afford health

#Dernières lignes
df_fao_healthydiet.tail()

	Code Domaine	Domaine	Code zone (M49)	Zone	Code Élément	Élément	Code Produit
1395	CAHD	Coût et abordabilité d'une alimentation saine\...	716	Zimbabwe	6132	Valeur	7006
1396	CAHD	Coût et abordabilité d'une alimentation saine\...	716	Zimbabwe	6132	Valeur	7006
1397	CAHD	Coût et abordabilité d'une alimentation saine\...	716	Zimbabwe	6132	Valeur	7006

Bilan :

- 194 valeurs manquantes dans colonne "valeur" (NaN)
- Pas de Pk native
- Pas de NaN sur les autres colonnes
- 175 pays différents

2.2.2 - Nettoyage

```
#Suppression des colonnes superflues et conversion des NaN en null
df_fao_healthydiet_c = df_fao_healthydiet.drop(columns=['Code Domai
df_fao_healthydiet_c['Valeur'] = pd.to_numeric(df_fao_healthydiet_c
df_fao_healthydiet_c = df_fao_healthydiet_c.fillna(0)
df_fao_healthydiet_c.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1400 entries, 0 to 1399
Data columns (total 5 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Code zone (M49)       1400 non-null   int64
1   Zone                  1400 non-null   object
2   Produit               1400 non-null   object
3   Année                 1400 non-null   int64
4   Valeur                1400 non-null   float64
dtypes: float64(1), int64(2), object(2)
memory usage: 54.8+ KB
```

✓ 2.2.3 - Mise en forme

```
#Mise en forme pivot
df_fao_healthydiet_p = df_fao_healthydiet_c.pivot_table(index=['Zone', 'Année'], columns='Produit', values='Number of people unable to afford a healthy diet (NUA), million')
```

Produit	Zone	Code zone (M49)	Année	Number of people unable to afford a healthy diet (NUA), million
0	Afrique du Sud	710	2017	35.0
1	Afrique du Sud	710	2018	35.3
2	Afrique du Sud	710	2019	35.9
3	Afrique du Sud	710	2020	37.4
4	Afrique du Sud	710	2021	37.6
...	...	...	...	...
1395	Îles Vierges britanniques	92	2020	0.0
1396	Îles Vierges	92	2021	0.0

```
#Mise en forme finale
df_fao_healthydiet_f = df_fao_healthydiet_p.rename(columns={'Zone':
df_fao_healthydiet_f.columns.name = None
df_fao_dispo_f = df_fao_dispo_f.dropna()
df_fao_healthydiet_f
```

	Pays	Code pays	Année	Pop sans moyen de se nourrir sainement (en million)
0	Afrique du Sud	710	2017	35.0
1	Afrique du Sud	710	2018	35.3
2	Afrique du Sud	710	2019	35.9
3	Afrique du Sud	710	2020	37.4
4	Afrique du Sud	710	2021	37.6
...	...	...	...	...
1395	Îles Vierges britanniques	92	2020	0.0
1396	Îles Vierges britanniques	92	2021	0.0
1397	Îles Vierges britanniques	92	2022	0.0
1398	Îles Vierges britanniques	92	2023	0.0

```
#Caractéristiques
df_fao_healthydiet_f.info()
print("\n")
df_fao_healthydiet_f.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1400 entries, 0 to 1399
Data columns (total 4 columns):
#   Column                                                                 Non-Null C
---  -
0    Pays                                                                1400 non-n
1    Code pays                                                            1400 non-n
2    Année                                                                1400 non-n
3    Pop sans moyen de se nourrir sainement (en million) 1400 non-n
dtypes: float64(1), int64(2), object(1)
memory usage: 43.9+ KB
```

	Pays	Code pays	Année	Pop sans moyen de se nourrir sainement (en million)
count	1400	1400.000000	1400.000000	1400.000000
unique	175	NaN	NaN	NaN
top	Afrique du Sud	NaN	NaN	NaN
freq	8	NaN	NaN	NaN
mean	NaN	419.497143	2020.500000	15.158643
std	NaN	249.400617	2.292107	61.546270
min	NaN	8.000000	2017.000000	0.000000
25%	NaN	196.000000	2018.750000	0.100000
50%	NaN	417.000000	2020.500000	1.300000

✓ 2.3 - Analyse exploratoire df_fao_PIB

✓ 2.3.1 - Evaluation du dataset

```
#Caractéristiques
df_fao_PIB.info()
```

```
print("\n")
df_fao_PIB.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2837 entries, 0 to 2836
Data columns (total 15 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Code Domaine                          2837 non-null   object
1   Domaine                              2837 non-null   object
2   Code zone (M49)                       2837 non-null   int64
3   Zone                                  2837 non-null   object
4   Code Élément                          2837 non-null   int64
5   Élément                              2837 non-null   object
6   Code Produit                          2837 non-null   int64
7   Produit                              2837 non-null   object
8   Code année                           2837 non-null   int64
9   Année                               2837 non-null   int64
10  Unité                                2837 non-null   object
11  Valeur                              2837 non-null   int64
12  Symbole                             2837 non-null   object
13  Description du Symbole               2837 non-null   object
14  Note                                0 non-null      float64
dtypes: float64(1), int64(6), object(8)
memory usage: 332.6+ KB
```

	Code Domaine	Domaine	Code zone (M49)	Zone	Code Élément	Élément	Cod Produit
count	2837	2837	2837.000000	2837	2837.0	2837	2837
unique	1	1	NaN	190	NaN	1	Na
top	FS	Données de la sécurité alimentaire	NaN	Afrique du Sud	NaN	Valeur	Na
freq	2837	2837	NaN	15	NaN	2837	Na
mean	NaN	NaN	425.136764	NaN	6126.0	NaN	22013
std	NaN	NaN	251.414818	NaN	0.0	NaN	0
min	NaN	NaN	4.000000	NaN	6126.0	NaN	22013
25%	NaN	NaN	208.000000	NaN	6126.0	NaN	22013
50%	NaN	NaN	426.000000	NaN	6126.0	NaN	22013
75%	NaN	NaN	642.000000	NaN	6126.0	NaN	22013
max	NaN	NaN	894.000000	NaN	6126.0	NaN	22013

#Premières lignes
df_fao_PIB.head()

	Code Domaine	Domaine	Code zone (M49)	Zone	Code Élément	Élément	Code Produit	
0	FS	Données de la sécurité alimentaire	4	Afghanistan	6126	Valeur	22013	h inter
1	FS	Données de la sécurité alimentaire	4	Afghanistan	6126	Valeur	22013	h inter
2	FS	Données de la	4	Afghanistan	6126	Valeur	22013	h

#Dernières lignes
df_fao_PIB.tail()

	Code Domaine	Domaine	Code zone (M49)	Zone	Code Élément	Élément	Code Produit	
2832	FS	Données de la sécurité alimentaire	716	Zimbabwe	6126	Valeur	22013	in
2833	FS	Données de la sécurité alimentaire	716	Zimbabwe	6126	Valeur	22013	in
2834	FS	Données de la sécurité alimentaire	716	Zimbabwe	6126	Valeur	22013	in
		Données						

Bilan :

- Colonne "Note" vide (NaN) : à supprimer
- Pas de pk native
- Pas d'autre colonne avec NaN
- 190 pays différents

✓ 2.3.2 - Nettoyage

```
#Suppression des colonnes superflues
df_fao_PIB_c = df_fao_PIB.drop(columns=['Code Domaine', 'Domaine', 'C
df_fao_PIB_c.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2837 entries, 0 to 2836
Data columns (total 5 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Code zone (M49)        2837 non-null   int64
1   Zone                   2837 non-null   object
2   Produit                2837 non-null   object
3   Année                  2837 non-null   int64
4   Valeur                 2837 non-null   int64
dtypes: int64(3), object(2)
memory usage: 110.9+ KB
```

✓ 2.3.3 - Mise en forme

```
#Mise en forme pivot
df_fao_PIB_p = df_fao_PIB_c.pivot_table(index=['Zone', 'Code zone (M49)'],
df_fao_PIB_p
```

Produit	Zone	Code zone (M49)	Année	PIB par habitant, (\$ PPA internationaux constants de 2021)
0	Afghanistan	4	2010	2849
1	Afghanistan	4	2011	2757
2	Afghanistan	4	2012	2985
3	Afghanistan	4	2013	3047
4	Afghanistan	4	2014	3018
...	...	...	...	...
2832	Îles Salomon	90	2020	2515
2833	Îles Salomon	90	2021	2518
2834	Îles Salomon	90	2022	2518
	Îles			

```
#Mise en forme finale
df_fao_PIB_f = df_fao_PIB_p.rename(columns={'Zone': 'Pays', 'Code zon
df_fao_PIB_f.columns.name = None
df_fao_PIB_f = df_fao_PIB_f.dropna()
df_fao_PIB_f
```

	Pays	Code pays	Année	PIB/hab (\$ PPA internationaux constants de 2021)
0	Afghanistan	4	2010	2849
1	Afghanistan	4	2011	2757
2	Afghanistan	4	2012	2985
3	Afghanistan	4	2013	3047
4	Afghanistan	4	2014	3018
...	...	...	...	...
2832	Îles Salomon	90	2020	2515
2833	Îles Salomon	90	2021	2518
2834	Îles Salomon	90	2022	2518
2835	Îles Salomon	90	2023	2524

```
#Caractéristiques
df_fao_PIB_f.info()
print("\n")
df_fao_PIB_f.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2837 entries, 0 to 2836
Data columns (total 4 columns):
#   Column                                     Non-Null Count
---  -
0    Pays                                     2837 non-null
1    Code pays                               2837 non-null
2    Année                                   2837 non-null
3    PIB/hab ($ PPA internationaux constants de 2021) 2837 non-null
dtypes: int64(3), object(1)
memory usage: 88.8+ KB
```

	Pays	Code pays	Année	PIB/hab (\$ PPA internationaux constants de 2021)
count	2837	2837.000000	2837.000000	2837.000000
unique	190	NaN	NaN	NaN
top	Afrique du Sud	NaN	NaN	NaN
freq	15	NaN	NaN	NaN
mean	NaN	425.136764	2016.981671	24660.194572
std	NaN	251.414818	4.306613	26016.369990
min	NaN	4.000000	2010.000000	829.000000
25%	NaN	208.000000	2013.000000	5531.000000
50%	NaN	426.000000	2017.000000	15070.000000

✓ 2.4 - Analyse exploratoire df_fao_population

✓ 2.4.1 - Evaluation du dataset

```
#Caractéristiques
df_fao_population.info()
```

```
print("\n")
df_fao_population.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9814 entries, 0 to 9813
Data columns (total 15 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Code Domaine                        9814 non-null   object
1   Domaine                            9814 non-null   object
2   Code zone (M49)                    9814 non-null   int64
3   Zone                               9814 non-null   object
4   Code Élément                       9814 non-null   int64
5   Élément                            9814 non-null   object
6   Code Produit                       9814 non-null   int64
7   Produit                            9814 non-null   object
8   Code année                         9814 non-null   int64
9   Année                             9814 non-null   int64
10  Unité                              9814 non-null   object
11  Valeur                             9814 non-null   float64
12  Symbole                            9814 non-null   object
13  Description du Symbole             9814 non-null   object
14  Note                               0 non-null      float64
dtypes: float64(2), int64(5), object(8)
memory usage: 1.1+ MB
```

	Code Domaine	Domaine	Code zone (M49)	Zone	Code Élément	Élément
count	9814	9814	9814.000000	9814	9814.000000	9814
unique	1	1	NaN	238	NaN	3
top	OA	Séries temporelles annuelles	NaN	Afghanistan	NaN	Population rurale
freq	9814	9814	NaN	42	NaN	3272
mean	NaN	NaN	435.598838	NaN	541.006114	NaN
std	NaN	NaN	251.613117	NaN	21.601525	NaN
min	NaN	NaN	4.000000	NaN	511.000000	NaN
25%	NaN	NaN	218.000000	NaN	511.000000	NaN
50%	NaN	NaN	438.000000	NaN	551.000000	NaN
75%	NaN	NaN	654.000000	NaN	561.000000	NaN
max	NaN	NaN	894.000000	NaN	561.000000	NaN

```
#Premières lignes
df_fao_population.head()
```

	Code Domaine	Domaine	Séries	Code zone (M49)	Zone	Code Élément	Élément	Code Produit	
0	OA	temporelles annuelles	Séries	4	Afghanistan	511	Population totale	3010	Pe Es
1	OA	temporelles annuelles	Séries	4	Afghanistan	551	Population rurale	3010	Pe Es
2	OA	temporelles annuelles	Séries	4	Afghanistan	561	Population urbaine	3010	Pe Es
3	OA	temporelles annuelles	Séries	4	Afghanistan	511	Population totale	3010	Pe Es

```
#Dernières lignes
df_fao_population.tail()
```

	Code Domaine	Domaine	Séries	Code zone (M49)	Zone	Code Élément	Élément	Code Produit	
9809	OA	temporelles annuelles	Séries	716	Zimbabwe	551	Population rurale	3010	
9810	OA	temporelles annuelles	Séries	716	Zimbabwe	561	Population urbaine	3010	
9811	OA	temporelles annuelles	Séries	716	Zimbabwe	511	Population totale	3010	
9812	OA	temporelles annuelles	Séries	716	Zimbabwe	551	Population rurale	3010	
9813	OA	temporelles annuelles	Séries	716	Zimbabwe	561	Population urbaine	3010	

Bilan :

- Colonne "Note" vide (NaN) : à supprimer
- Pas de pk native
- Pas d'autre colonne avec des NaN
- 238 pays différents

✓ 2.4.2 - Nettoyage

```
#Suppression des colonnes superflues
df_fao_population_c = df_fao_population.drop(columns=['Code Domaine'])
df_fao_population_c.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 9814 entries, 0 to 9813
Data columns (total 5 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Code zone (M49)        9814 non-null  int64
1   Zone                   9814 non-null  object
2   Élément                9814 non-null  object
3   Année                  9814 non-null  int64
4   Valeur                 9814 non-null  float64
dtypes: float64(1), int64(2), object(2)
memory usage: 383.5+ KB
```

✓ 2.4.3 - Mise en forme


```
#Mise en forme pivot
df_fao_population_p = df_fao_population_c.pivot_table(index=['Zone', 'Année'], columns='Code zone (M49)', values=[
    'Population rurale', 'Population totale', 'Population urbaine'])
```

Élément	Zone	Code zone (M49)	Année	Population rurale	Population totale	Population urbaine
0	Afghanistan	4	2010	21966.187	28284.089	6836.980
1	Afghanistan	4	2011	22594.126	29347.708	7114.473
2	Afghanistan	4	2012	23280.663	30560.034	7416.295
3	Afghanistan	4	2013	23997.856	31622.704	7733.832
4	Afghanistan	4	2014	24703.798	32792.523	8054.222
...	...	...	...	...	...	...
3293	Îles Wallis-et-Futuna	876	2019	11.617	11.686	0.000
3294	Îles Wallis-et-Futuna	876	2020	11.551	11.616	0.000
3295	Îles Wallis-et-Futuna	876	2021	11.494	11.568	0.000
	Îles Wallis-					

```
#Mise en forme finale
df_fao_population_f = df_fao_population_p.rename(columns={'Zone':'F
colonne_a_deplacer = df_fao_population_f.pop('Pop totale (pour 1000
df_fao_population_f.insert(5, 'Pop totale (pour 1000)', colonne_a_d
df_fao_population_f.columns.name = None
df_fao_population_f = df_fao_population_f.dropna()
df_fao_population_f
```

	Pays	Code pays	Année	Pop rurale (pour 1000)	Pop urbaine (pour 1000)	Pop totale (pour 1000)
0	Afghanistan	4	2010	21966.187	6836.980	28284.089
1	Afghanistan	4	2011	22594.126	7114.473	29347.708
2	Afghanistan	4	2012	23280.663	7416.295	30560.034
3	Afghanistan	4	2013	23997.856	7733.832	31622.704
4	Afghanistan	4	2014	24703.798	8054.222	32792.523
...	...	...	...	...	...	...
3293	Îles Wallis- et-Futuna	876	2019	11.617	0.000	11.686
3294	Îles Wallis- et-Futuna	876	2020	11.551	0.000	11.616
3295	Îles Wallis- et-Futuna	876	2021	11.494	0.000	11.568
	Îles Wallis-					

```
#Caractéristiques
df_fao_population_f.info()
print("\n")
df_fao_population_f.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 3244 entries, 0 to 3297
Data columns (total 6 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Pays                                  3244 non-null   object
1   Code pays                            3244 non-null   int64
2   Année                                3244 non-null   int64
3   Pop rurale (pour 1000)               3244 non-null   float64
4   Pop urbaine (pour 1000)              3244 non-null   float64
5   Pop totale (pour 1000)               3244 non-null   float64
dtypes: float64(3), int64(2), object(1)
memory usage: 177.4+ KB
```

	Pays	Code pays	Année	Pop rurale (pour 1000)	Pop urbaine (pour 1000)
count	3244	3244.000000	3244.000000	3244.000000	3244.000000
unique	234	NaN	NaN	NaN	NaN
top	Afghanistan	NaN	NaN	NaN	NaN
freq	14	NaN	NaN	NaN	NaN
mean	NaN	434.157830	2016.507707	17286.765677	21284.733308
std	NaN	251.487165	4.028223	81436.795670	84835.956158
min	NaN	4.000000	2010.000000	0.000000	0.000000
25%	NaN	214.000000	2013.000000	96.047000	313.533750
50%	NaN	434.000000	2017.000000	1635.663500	3081.828000
75%	NaN	646.000000	2020.000000	9422.752500	10406.699500

✓ 2.5 - Analyse exploratoire df_fao_stability

✓ 2.5.1 - Evaluation du dataset

```
#Caractéristiques
```

```
#Caractéristiques
df_fao_stability.info()
print("\n")
df_fao_stability.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2535 entries, 0 to 2534
Data columns (total 15 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Code Domaine                         2535 non-null   object
1   Domaine                             2535 non-null   object
2   Code zone (M49)                     2535 non-null   int64
3   Zone                                2535 non-null   object
4   Code Élément                        2535 non-null   int64
5   Élément                             2535 non-null   object
6   Code Produit                        2535 non-null   int64
7   Produit                             2535 non-null   object
8   Code année                          2535 non-null   int64
9   Année                              2535 non-null   int64
10  Unité                               0 non-null      float64
11  Valeur                             2535 non-null   float64
12  Symbole                            2535 non-null   object
13  Description du Symbole              2535 non-null   object
14  Note                                0 non-null      float64
dtypes: float64(3), int64(5), object(7)
memory usage: 297.2+ KB
```

	Code Domaine	Domaine	Code zone (M49)	Zone	Code Élément	Élément	Pro
count	2535	2535	2535.000000	2535	2535.0	2535	2
unique	1	1	NaN	196	NaN	1	
top	FS	Données de la sécurité alimentaire	NaN	Afghanistan	NaN	Valeur	
freq	2535	2535	NaN	13	NaN	2535	
mean	NaN	NaN	428.475740	NaN	6125.0	NaN	2
std	NaN	NaN	254.651457	NaN	0.0	NaN	
min	NaN	NaN	4.000000	NaN	6125.0	NaN	2
25%	NaN	NaN	208.000000	NaN	6125.0	NaN	2
50%	NaN	NaN	426.000000	NaN	6125.0	NaN	2
75%	NaN	NaN	646.000000	NaN	6125.0	NaN	2

max

NaN

NaN

894.000000

NaN

6125.0

NaN

21032

#Premières lignes
df_fao_stability.head()

	Code Domaine	Domaine	Code zone (M49)	Zone	Code Élément	Élément	Code Produit	
0	FS	Données de la sécurité alimentaire	4	Afghanistan	6125	Valeur	21032	pr ab viole
1	FS	Données de la sécurité alimentaire	4	Afghanistan	6125	Valeur	21032	pr ab viole
2	FS	Données de la sécurité alimentaire	4	Afghanistan	6125	Valeur	21032	pr ab viole

#Dernières lignes
df_fao_stability.tail()

	Code Domaine	Domaine	Code zone (M49)	Zone	Code Élément	Élément	Code Produit	
2530	FS	Données de la sécurité alimentaire	716	Zimbabwe	6125	Valeur	21032	vi
2531	FS	Données de la sécurité alimentaire	716	Zimbabwe	6125	Valeur	21032	vi
2532	FS	Données de la sécurité alimentaire	716	Zimbabwe	6125	Valeur	21032	vi

2533	FS	Données de la sécurité alimentaire	716	Zimbabwe	6125	Valeur	21032	vi
------	----	---	-----	----------	------	--------	-------	----

Bilan :

- Colonnes "Note" et "Unité" vides (NaN) : à supprimer
- Pas de pk native
- Pas d'autre colonne avec des NaN
- 196 pays différents

✓ 2.5.2 - Nettoyage

```
#Suppression des colonnes superflues
df_fao_stability_c = df_fao_stability.drop(columns=['Code Domaine'],
df_fao_stability_c.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2535 entries, 0 to 2534
Data columns (total 5 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Code zone (M49)       2535 non-null   int64
1   Zone                  2535 non-null   object
2   Produit               2535 non-null   object
3   Année                2535 non-null   int64
4   Valeur                2535 non-null   float64
dtypes: float64(1), int64(2), object(2)
memory usage: 99.2+ KB
```

✓ 2.5.3 - Mise en forme

```
#Mise en forme pivot
df_fao_stability_p = df_fao_stability_c.pivot_table(index=['Zone', 'Produit'],
df_fao_stability_p
```

Produit	Zone	Code zone (M49)	Année	Stabilité politique et absence de violence/terrorisme (indice)
0	Afghanistan	4	2010	-2.58
1	Afghanistan	4	2011	-2.50
2	Afghanistan	4	2012	-2.42
3	Afghanistan	4	2013	-2.52
4	Afghanistan	4	2014	-2.41
...	...	...	...	...
2530	Îles Salomon	90	2018	0.36
2531	Îles Salomon	90	2019	0.50
2532	Îles Salomon	90	2020	0.56
	Îles			

```
#Mise en forme finale
df_fao_stability_f = df_fao_stability_p.rename(columns={'Zone': 'Pay
df_fao_stability_f.columns.name = None
df_fao_stability_f = df_fao_stability_f.dropna()
df_fao_stability_f
```

	Pays	Code pays	Année	Indice stabilité politique
0	Afghanistan	4	2010	-2.58
1	Afghanistan	4	2011	-2.50
2	Afghanistan	4	2012	-2.42
3	Afghanistan	4	2013	-2.52
4	Afghanistan	4	2014	-2.41
...	...	...	...	...
2530	Îles Salomon	90	2018	0.36
2531	Îles Salomon	90	2019	0.50
2532	Îles Salomon	90	2020	0.56
2533	Îles Salomon	90	2021	0.54
2534	Îles Salomon	90	2022	0.41

2535 rows x 4 columns


```
#Caractéristiques
df_fao_stability_f.info()
print("\n")
df_fao_stability_f.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 2535 entries, 0 to 2534
Data columns (total 4 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Pays                                2535 non-null   object
1   Code pays                          2535 non-null   int64
2   Année                             2535 non-null   int64
3   Indice stabilité politique         2535 non-null   float64
dtypes: float64(1), int64(2), object(1)
memory usage: 79.3+ KB
```

	Pays	Code pays	Année	Indice stabilité politique
count	2535	2535.000000	2535.000000	2535.000000
unique	196	NaN	NaN	NaN
top	Afghanistan	NaN	NaN	NaN
freq	13	NaN	NaN	NaN
mean	NaN	428.475740	2016.004734	-0.068998
std	NaN	254.651457	3.741865	0.993756
min	NaN	4.000000	2010.000000	-3.130000
25%	NaN	208.000000	2013.000000	-0.680000
50%	NaN	426.000000	2016.000000	0.020000
75%	NaN	646.000000	2019.000000	0.780000
max	NaN	894.000000	2022.000000	1.960000

✓ 2.6 - Analyse exploratoire df_wbg_index

✓ 2.6.1 - Evaluation du dataset

```
#Caractéristiques
df_wbg_index.info()
print("\n")
df_wbg_index.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1307 entries, 0 to 1306
Data columns (total 20 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Country Name          1304 non-null   object
1   Country Code          1302 non-null   object
2   Series Name           1302 non-null   object
3   Series Code           1302 non-null   object
4   2010 [YR2010]         1302 non-null   object
5   2011 [YR2011]         1302 non-null   object
6   2012 [YR2012]         1302 non-null   object
7   2013 [YR2013]         1302 non-null   object
8   2014 [YR2014]         1302 non-null   object
9   2015 [YR2015]         1302 non-null   object
10  2016 [YR2016]         1302 non-null   object
11  2017 [YR2017]         1302 non-null   object
12  2018 [YR2018]         1302 non-null   object
13  2019 [YR2019]         1302 non-null   object
14  2020 [YR2020]         1302 non-null   object
15  2021 [YR2021]         1302 non-null   object
16  2022 [YR2022]         1302 non-null   object
17  2023 [YR2023]         1302 non-null   object
18  2024 [YR2024]         1302 non-null   object
19  2025 [YR2025]         1302 non-null   object
dtypes: object(20)
memory usage: 204.3+ KB
```

	Country Name	Country Code	Series Name	Series Code	2010 [YR2010]	2025 [YR2025]
count	1304	1302	1302	1302	1302	1302
unique	219	217	6	6	740	5
top	Afghanistan	AFG	Access to electricity (% of population)	EG.ELC.ACCS.ZS	..	..
freq	6	6	217	217	218	6

```
#Premières lignes
df_wbg_index.head()
```

	Country Name	Country Code	Series Name	Series Code	2010 [YR2010]	
0	Afghanistan	AFG	Access to electricity (% of population)	EG.ELC.ACCS.ZS	42.7	
1	Afghanistan	AFG	Logistics performance index: Overall (1=low to...	LP.LPI.OVRL.XQ	2.24	
2	Afghanistan	AFG	Logistics performance index: Frequency with wh...	LP.LPI.TIME.XQ	2.61	
3	Afghanistan	AFG	Logistics performance index: Quality of trade ...	LP.LPI.INFR.XQ	1.87	
4	Afghanistan	AFG	Control of Corruption: Estimate	CC.EST	-1.64539110660553	-1.6

```
#Dernières lignes
df_wbg_index.tail(6)
```

	Country Name	Country Code	Series Name	Series Code	2010 [YR2010]	2011 [YR2011]
1301	Zimbabwe	ZWE	Rule of Law: Estimate	RL.EST	-1.83763182163239	-1.79394936
1302	NaN	NaN	NaN	NaN	NaN	NaN
1303	NaN	NaN	NaN	NaN	NaN	NaN
1304	NaN	NaN	NaN	NaN	NaN	NaN
1305	Data from database: World Development Indicators	NaN	NaN	NaN	NaN	NaN
1306	Last Updated: 02/24/2026	NaN	NaN	NaN	NaN	NaN

Bilan :

- 5 dernières lignes vides (NaN) : à supprimer
- Pas de colonne avec NaN
- Pas d'autre ligne avec NaN
- 217 pays différents
- Pas de pk native

✓ 2.6.2 - Nettoyage

```
#Suppression des colonnes et lignes superflues
df_wbg_index_c = df_wbg_index.drop(columns=['Series Code'])
df_wbg_index_c = df_wbg_index_c .dropna(subset=['Country Code'])
df_wbg_index_c.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 1302 entries, 0 to 1301
Data columns (total 19 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Country Name                          1302 non-null   object
1   Country Code                          1302 non-null   object
2   Series Name                           1302 non-null   object
3   2010 [YR2010]                        1302 non-null   object
4   2011 [YR2011]                        1302 non-null   object
5   2012 [YR2012]                        1302 non-null   object
6   2013 [YR2013]                        1302 non-null   object
7   2014 [YR2014]                        1302 non-null   object
8   2015 [YR2015]                        1302 non-null   object
9   2016 [YR2016]                        1302 non-null   object
10  2017 [YR2017]                        1302 non-null   object
11  2018 [YR2018]                        1302 non-null   object
12  2019 [YR2019]                        1302 non-null   object
13  2020 [YR2020]                        1302 non-null   object
14  2021 [YR2021]                        1302 non-null   object
15  2022 [YR2022]                        1302 non-null   object
16  2023 [YR2023]                        1302 non-null   object
17  2024 [YR2024]                        1302 non-null   object
18  2025 [YR2025]                        1302 non-null   object
dtypes: object(19)
memory usage: 203.4+ KB
```

✓ 2.6.3 - Mise en forme

```
#Mise en forme tableau
```

```
df_wbg_index_t = df_wbg_index_c.melt(id_vars=['Country Code', 'Country Name', 'Series Name', 'Année brute'], value_vars=['Année brute'], var_name='Année brute', value_name='Valeur')  
df_wbg_index_t
```

	Country Code	Country Name	Series Name	Année brute	Valeur	Année
0	AFG	Afghanistan	Access to electricity (% of population)	2010 [YR2010]	42.7	2010
1	AFG	Afghanistan	Logistics performance index: Overall (1=low to...)	2010 [YR2010]	2.24	2010
2	AFG	Afghanistan	Logistics performance index: Frequency with wh...	2010 [YR2010]	2.61	2010
3	AFG	Afghanistan	Logistics performance index: Quality of	2010 [YR2010]	1.87	2010

```
#Mise en forme pivot
```

```
df_wbg_index_p = df_wbg_index_t.pivot_table(index=['Country Code', '
df_wbg_index_p = df_wbg_index_p.drop(columns=['Logistics performanc
df_wbg_index_p
```

Series Name	Country Code	Country Name	Année	Access to electricity (% of population)	Control of Corruption: Estimate	Logistics performance index (1=low, 5=high)
0	ABW	Aruba	2010	93.4	1.12129557132721	
1	ABW	Aruba	2011	100	1.10294651985168	
2	ABW	Aruba	2012	100	1.09523594379425	
3	ABW	Aruba	2013	100	1.11960065364838	
4	ABW	Aruba	2014	100	1.01400101184845	
...	...	...	...	...	...	...
3467	ZWE	Zimbabwe	2021	49	-1.27714729309082	
3468	ZWE	Zimbabwe	2022	50.1	-1.25996947288513	
3469	ZWE	Zimbabwe	2023	62	-1.26121604442596	
3470	ZWE	Zimbabwe	2024	..	..	

```
#Mise en forme finale
```

```
df_wbg_index_f = df_wbg_index_p.rename(columns={'Country Code':'Id'})
df_wbg_index_f.columns.name = None
df_wbg_index_f = df_wbg_index_f.replace('..', np.nan)
df_wbg_index_f = df_wbg_index_f.dropna()
df_wbg_index_f
```

	Id pays	Pays	Année	Taux pop accès électricité	Indice corruption	Indice perf log	
16	AFG	Afghanistan	2010	42.7	-1.64539110660553	2.24	-1
18	AFG	Afghanistan	2012	69.1	-1.43037283420563	2.3	-1
20	AFG	Afghanistan	2014	89.5	-1.36493408679962	2.069573	-1
22	AFG	Afghanistan	2016	97.7	-1.54022777080536	2.141282	-1
24	AFG	Afghanistan	2018	93.4	-1.50287592411041	1.95	-1
...	...	...	...	...	...	...	...
3458	ZWE	Zimbabwe	2012	44	-1.38180339336395	2.55	-1
3460	ZWE	Zimbabwe	2014	32.3	-1.40475881099701	2.33928	-1
3462	ZWE	Zimbabwe	2016	42.5	-1.28866481781006	2.082408	-1
3464	ZWE	Zimbabwe	2018	45.4	-1.24637961387634	2.12	-1
3468	ZWE	Zimbabwe	2022	50.1	-1.25996947288513	2.5	-1


```
#Caractéristiques
df_wbg_index_f.info()
print("\n")
df_wbg_index_f.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 922 entries, 16 to 3468
Data columns (total 7 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Id pays                               922 non-null    object
1   Pays                                  922 non-null    object
2   Année                                 922 non-null    object
3   Taux pop accès électricité           922 non-null    object
4   Indice corruption                    922 non-null    object
5   Indice perf log                      922 non-null    object
6   Indice état de droit                 922 non-null    object
dtypes: object(7)
memory usage: 89.9+ KB
```

	Id pays	Pays	Année	Taux pop accès électricité	Indice corruption	Indice perf log
count	922	922	922	922	922	922
unique	168	168	6	320	922	507
top	AFG	Afghanistan	2016	100	-1.25996947288513	2.5

✓ 2.7 - Analyse exploratoire df_wbg_temperature

✓ 2.7.1 - Evaluation du dataset

```
#Caractéristiques
df_wbg_temperature.info()
print("\n")
df_wbg_temperature.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 198 entries, 0 to 197
Data columns (total 18 columns):
#   Column                Non-Null Count  Dtype
---  -
0   Country Name          195 non-null    object
1   Country Code          193 non-null    object
2   Series Name           193 non-null    object
3   Series Code           193 non-null    object
4   2010 [YR2010]         193 non-null    object
5   2011 [YR2011]         193 non-null    object
6   2012 [YR2012]         193 non-null    object
7   2013 [YR2013]         193 non-null    object
8   2014 [YR2014]         193 non-null    object
9   2015 [YR2015]         193 non-null    object
10  2016 [YR2016]         193 non-null    object
11  2017 [YR2017]         193 non-null    object
12  2018 [YR2018]         193 non-null    object
13  2019 [YR2019]         193 non-null    object
14  2020 [YR2020]         193 non-null    object
15  2021 [YR2021]         193 non-null    object
16  2022 [YR2022]         193 non-null    object
17  2023 [YR2023]         193 non-null    object
dtypes: object(18)
memory usage: 28.0+ KB
```

	Country Name	Country Code	Series Name	Series Code	2010 [YR2010]	[YR2
count	195	193	193	193	193	
unique	195	193	1	1	193	
top	Afghanistan	AFG	Land Surface Temperature	EN.LND.LTMP.DC	29.6243831	
freq	1	1	193	193	1	

```
#Premières lignes
df_wbg_temperature.head()
```

	Country Name	Country Code	Series Name	Series Code	2010 [YR2010]	2011 [YR2011]
0	Afghanistan	AFG	Land Surface Temperature	EN.LND.LTMP.DC	29.6243831	29.1250018
1	Albania	ALB	Land Surface Temperature	EN.LND.LTMP.DC	19.0624193	19.5603627
2	Algeria	DZA	Land Surface Temperature	EN.LND.LTMP.DC	38.8769805	37.8767998
3	Andorra	AND	Land Surface Temperature	EN.LND.LTMP.DC	8.53112755	11.72457
4	Angola	AGO	Land Surface Temperature	EN.LND.LTMP.DC	29.8113382	29.3119114

```
#Dernières lignes
df_wbg_temperature.tail(6)
```

	Country Name	Country Code	Series Name	Series Code	2010 [YR2010]	20 [YR20:]
192	Zimbabwe	ZWE	Land Surface Temperature	EN.LND.LTMP.DC	31.6876496	31.81270
193	NaN	NaN	NaN	NaN	NaN	N
194	NaN	NaN	NaN	NaN	NaN	N
195	NaN	NaN	NaN	NaN	NaN	N
196	Data from database: Environment Social and Gov...	NaN	NaN	NaN	NaN	N
197	Last Updated: 07/30/2025	NaN	NaN	NaN	NaN	N

Bilan :

- 5 dernières lignes vides (NaN) : à supprimer
- 193 pays différents
- Pas de colonne avec NaN
- Pas d'autre ligne avec NaN
- pk : "country code" ou "country name"

✓ 2.7.2 - Nettoyage

```
#Suppression des colonnes et lignes superflues
df_wbg_temperature_c = df_wbg_temperature.drop(columns=['Series Cod
df_wbg_temperature_c = df_wbg_temperature_c .dropna(subset=['Countr
df_wbg_temperature_c.info()
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 193 entries, 0 to 192
Data columns (total 17 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Country Name                          193 non-null    object
1   Country Code                          193 non-null    object
2   Series Name                           193 non-null    object
3   2010 [YR2010]                         193 non-null    object
4   2011 [YR2011]                         193 non-null    object
5   2012 [YR2012]                         193 non-null    object
6   2013 [YR2013]                         193 non-null    object
7   2014 [YR2014]                         193 non-null    object
8   2015 [YR2015]                         193 non-null    object
9   2016 [YR2016]                         193 non-null    object
10  2017 [YR2017]                         193 non-null    object
11  2018 [YR2018]                         193 non-null    object
12  2019 [YR2019]                         193 non-null    object
13  2020 [YR2020]                         193 non-null    object
14  2021 [YR2021]                         193 non-null    object
15  2022 [YR2022]                         193 non-null    object
16  2023 [YR2023]                         193 non-null    object
dtypes: object(17)
memory usage: 27.1+ KB
```

✓ 2.7.3 - Mise en forme

```
#Mise en forme tableau
```

```
df_wbg_temperature_t = df_wbg_temperature_c.melt(id_vars=['Country  
df_wbg_temperature_t[['Année', 'Code Année']] = df_wbg_temperature_  
df_wbg_temperature_t
```

	Country Code	Country Name	Series Name	Année brute	Valeur	Année	Cod Anné
0	AFG	Afghanistan	Land Surface Temperature	2010 [YR2010]	29.6243831	2010	[YR2010]
1	ALB	Albania	Land Surface Temperature	2010 [YR2010]	19.0624193	2010	[YR2010]
2	DZA	Algeria	Land Surface Temperature	2010 [YR2010]	38.8769805	2010	[YR2010]
3	AND	Andorra	Land Surface Temperature	2010 [YR2010]	8.53112755	2010	[YR2010]
4	AGO	Angola	Land Surface Temperature	2010 [YR2010]	29.8113382	2010	[YR2010]
...	...	...	...	...	...	...	...

```
#Mise en forme pivot
df_wbg_temperature_p = df_wbg_temperature_t.pivot_table(index=['Cou
df_wbg_temperature_p
```

Series Name	Country Code	Country Name	Année	Land Surface Temperature
0	AFG	Afghanistan	2010	29.6243831
1	AFG	Afghanistan	2011	29.1250018
2	AFG	Afghanistan	2012	27.3746873
3	AFG	Afghanistan	2013	29.1247789
4	AFG	Afghanistan	2014	28.6281367
...	...	...	...	...
2697	ZWE	Zimbabwe	2019	33.8128838
2698	ZWE	Zimbabwe	2020	32.4368735
2699	ZWE	Zimbabwe	2021	31.4370772
2700	ZWE	Zimbabwe	2022	..
2701	ZWE	Zimbabwe	2023	..

2702 rows × 4 columns

```
#Mise en forme finale
df_wbg_temperature_f = df_wbg_temperature_p.rename(columns={'Country': 'Country'})
df_wbg_temperature_f.columns.name = None
df_wbg_temperature_f = df_wbg_temperature_f.replace('.', np.nan)
df_wbg_temperature_f = df_wbg_temperature_f.dropna()
df_wbg_temperature_f
```

	Id pays	Pays	Année	Temp surface terrestre (°C)
0	AFG	Afghanistan	2010	29.6243831
1	AFG	Afghanistan	2011	29.1250018
2	AFG	Afghanistan	2012	27.3746873
3	AFG	Afghanistan	2013	29.1247789
4	AFG	Afghanistan	2014	28.6281367
...	...	...	...	...
2695	ZWE	Zimbabwe	2017	30.4378471
2696	ZWE	Zimbabwe	2018	32.6869318
2697	ZWE	Zimbabwe	2019	33.8128838
2698	ZWE	Zimbabwe	2020	32.4368735
2699	ZWE	Zimbabwe	2021	31.4370772

2296 rows × 4 columns


```
#Caractéristiques
df_wbg_temperature_f.info()
print("\n")
df_wbg_temperature_f.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 2296 entries, 0 to 2699
Data columns (total 4 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Id pays                               2296 non-null   object
1   Pays                                  2296 non-null   object
2   Année                                 2296 non-null   object
3   Temp surface terrestre (°C)          2296 non-null   object
dtypes: object(4)
memory usage: 154.2+ KB
```

	Id pays	Pays	Année	Temp surface terrestre (°C)
count	2296	2296	2296	2296
unique	192	192	12	2296
top	AFG	Afghanistan	2010	31.4370772
freq	12	12	192	1

✓ 2.8 - Analyse exploratoire df_cepii_distance

✓ 2.8.1 - Evaluation du dataset

```
#Caractéristiques
df_cepii_distance.info()
print("\n")
df_cepii_distance.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 50176 entries, 0 to 50175
Data columns (total 14 columns):
#   Column                Non-Null Count  Dtype
---  -
0   iso_o                  50176 non-null  object
1   iso_d                  50176 non-null  object
2   contig                 50176 non-null  int64
3   comlang_off            50176 non-null  int64
4   comlang_ethno          50176 non-null  int64
5   colony                 50176 non-null  int64
6   comcol                 50176 non-null  int64
7   curcol                 50176 non-null  int64
8   col45                  50176 non-null  int64
9   smctry                 50176 non-null  int64
10  dist                   50176 non-null  object
11  distcap                50176 non-null  object
12  distw                  50176 non-null  object
13  distwces               50176 non-null  object
dtypes: int64(8), object(6)
memory usage: 5.4+ MB
```

	iso_o	iso_d	contig	comlang_off	comlang_ethno	co
count	50176	50176	50176.000000	50176.000000	50176.000000	50176.00
unique	224	224	NaN	NaN	NaN	
top	ABW	ABW	NaN	NaN	NaN	
freq	224	224	NaN	NaN	NaN	
mean	NaN	NaN	0.012277	0.174386	0.169165	0.00
std	NaN	NaN	0.110120	0.379445	0.374901	0.09
min	NaN	NaN	0.000000	0.000000	0.000000	0.00
25%	NaN	NaN	0.000000	0.000000	0.000000	0.00
50%	NaN	NaN	0.000000	0.000000	0.000000	0.00
75%	NaN	NaN	0.000000	0.000000	0.000000	0.00
max	NaN	NaN	1.000000	1.000000	1.000000	1.00

```
#Premières lignes
df_cepii_distance.head()
```

	iso_o	iso_d	contig	comlang_off	comlang_ethno	colony	comcol	c
0	ABW	ABW	0	0	0	0	0	
1	ABW	AFG	0	0	0	0	0	
2	ABW	AGO	0	0	0	0	0	
3	ABW	AIA	0	0	1	0	0	
4	ABW	ALB	0	0	0	0	0	

```
#Dernières lignes
df_cepii_distance.tail()
```

	iso_o	iso_d	contig	comlang_off	comlang_ethno	colony	comco	c
50171	ZWE	YUG	0	0	0	0	0	
50172	ZWE	ZAF	1	1	1	0	0	
50173	ZWE	ZAR	0	0	0	0	0	
50174	ZWE	ZMB	1	1	1	0	0	
50175	ZWE	ZWE	0	0	0	0	0	

Bilan :

- Pas de colonne ni de ligne avec NaN
- 224 pays différents
- Pas de pk native : "iso_o"&"iso_d"

✓ 2.8.2 - Nettoyage

```
#Conservation des distances avec la France
df_cepii_distance_france = df_cepii_distance[df_cepii_distance['iso_c'] == 'FR']
df_cepii_distance_france.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 224 entries, 0 to 223
Data columns (total 14 columns):
#   Column                Non-Null Count  Dtype
---  -
0   iso_o                  224 non-null   object
1   iso_d                  224 non-null   object
2   contig                 224 non-null   int64
3   comlang_off            224 non-null   int64
4   comlang_ethno          224 non-null   int64
5   colony                 224 non-null   int64
6   comcol                 224 non-null   int64
7   curcol                 224 non-null   int64
8   col45                  224 non-null   int64
9   smctry                 224 non-null   int64
10  dist                   224 non-null   object
11  distcap                224 non-null   object
12  distw                  224 non-null   object
13  distwces               224 non-null   object
dtypes: int64(8), object(6)
memory usage: 24.6+ KB
```

```
#Suppression des colonnes superflues
df_cepii_distance_c = df_cepii_distance_france.drop(columns=['iso_o', 'contig', 'comlang_off', 'comlang_ethno', 'colony', 'comcol', 'curcol', 'col45', 'smctry', 'distwces'])
df_cepii_distance_c.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 224 entries, 0 to 223
Data columns (total 2 columns):
#   Column  Non-Null Count  Dtype
---  -
0   iso_d    224 non-null   object
1   distw    224 non-null   object
dtypes: object(2)
memory usage: 3.6+ KB
```

✓ 2.8.3 - Mise en forme

```
#Mise en forme finale
df_cepii_distance_f = df_cepii_distance_c.rename(columns={'iso_d': '
df_cepii_distance_f = df_cepii_distance_f.dropna()
df_cepii_distance_f
```

	Id pays	Distance avec la France (km)
0	ABW	7716,752
1	AFG	5500,665
2	AGO	6384,805
3	AIA	6743,427
4	ALB	1499,451
...	...	...
219	YUG	1429,045
220	ZAF	8769,679
221	ZAR	6036,588
222	ZMB	7236,737
223	ZWE	7771,569

224 rows × 2 columns

```
#Caractéristiques
df_cepii_distance_f.info()
print("\n")
df_cepii_distance_f.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 224 entries, 0 to 223
Data columns (total 2 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Id pays                              224 non-null    object
1   Distance avec la France (km)        224 non-null    object
dtypes: object(2)
memory usage: 3.6+ KB
```

	Id pays	Distance avec la France (km)
count	224	224
unique	224	220
top	ABW	.
freq	1	5

✓ 2.9 - Analyse exploratoire df_cepii_langues

✓ 2.9.1 - Evaluation dataset

```
#Caractéristiques
df_cepii_langue.info()
print("\n")
df_cepii_langue.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 238 entries, 0 to 237
Data columns (total 34 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   iso2                                  237 non-null    object
1   iso3                                  238 non-null    object
2   cnum                                  238 non-null    int64
3   country                              238 non-null    object
4   pays                                  238 non-null    object
5   area                                  238 non-null    int64
6   dis_int                              238 non-null    float64
```

```

7   landlocked      238 non-null    int64
8   continent      238 non-null    object
9   city_en        238 non-null    object
10  city_fr         238 non-null    object
11  lat             238 non-null    float64
12  lon             238 non-null    float64
13  cap             238 non-null    int64
14  maincity        238 non-null    int64
15  citynum         238 non-null    object
16  langoff_1       238 non-null    object
17  langoff_2       238 non-null    object
18  langoff_3       238 non-null    object
19  lang20_1        238 non-null    object
20  lang20_2        238 non-null    object
21  lang20_3        238 non-null    object
22  lang20_4        238 non-null    object
23  lang9_1         238 non-null    object
24  lang9_2         238 non-null    object
25  lang9_3         238 non-null    object
26  lang9_4         238 non-null    object
27  colonizer1      238 non-null    object
28  colonizer2      238 non-null    object
29  colonizer3      238 non-null    object
30  colonizer4      238 non-null    object
31  short_colonizer1 238 non-null    object
32  short_colonizer2 238 non-null    object
33  short_colonizer3 238 non-null    object
dtypes: float64(3), int64(5), object(26)
memory usage: 63.3+ KB

```

	iso2	iso3	cnum	country	pays	area	dis_in
count	237	238	238.000000	238	238	2.380000e+02	238.000000
unique	224	225	NaN	225	225	NaN	NaN
top	AU	AUS	NaN	Australia	Australie	NaN	NaN
freq	2	2	NaN	2	2	NaN	NaN
mean	NaN	NaN	436.298319	NaN	NaN	7.581392e+05	203.882930
std	NaN	NaN	256.734227	NaN	NaN	2.056226e+06	256.833910
min	NaN	NaN	4.000000	NaN	NaN	7.000000e+00	0.995130
25%	NaN	NaN	212.500000	NaN	NaN	9.551250e+03	36.745790
50%	NaN	NaN	432.000000	NaN	NaN	1.058540e+05	122.360900
75%	NaN	NaN	657.750000	NaN	NaN	5.385482e+05	275.997450
max	NaN	NaN	931.000000	NaN	NaN	1.707540e+07	1554.244000

```
#Premières lignes
df_cepii_langue.head()
```

	iso2	iso3	cnum	country	pays	area	dis_int	landlock
0	AW	ABW	533	Aruba	Aruba	193	5.225315	
1	AF	AFG	4	Afghanistan	Afghanistan	652225	303.761400	
2	AO	AGO	24	Angola	Angola	1246700	419.966600	
3	AI	AIA	660	Anguilla	Anguilla	102	3.798690	
4	AL	ALB	8	Albania	Albanie	28748	63.773110	

✓ 2.9.2 - Nettoyage

```
#Identification erreur colonne "iso2"
df_cepii_langue[df_cepii_langue['iso2'].isnull()]
```

	iso2	iso3	cnum	country	pays	area	dis_int	landlocked	cc
149	NaN	NAM	516	Namibia	Namibie	825518	341.741	0	

```
#Correction erreur colonne "iso2" (la valeur "Na" pour la Namibi a
df_cepii_langue.loc[df_cepii_langue['iso2'].isnull(), 'iso2'] = 'NA'
```

```
#Caractéristiques
df_cepii_langue.info()
print("\n")
df_cepii_langue.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 238 entries, 0 to 237
Data columns (total 34 columns):
#   Column                Non-Null Count  Dtype
---  -
0   iso2                  238 non-null    object
1   iso3                  238 non-null    object
2   cnum                  238 non-null    int64
```



```

3    country      238 non-null    object
4    pays         238 non-null    object
5    area         238 non-null    int64
6    dis_int      238 non-null    float64
7    landlocked   238 non-null    int64
8    continent    238 non-null    object
9    city_en      238 non-null    object
10   city_fr      238 non-null    object
11   lat          238 non-null    float64
12   lon          238 non-null    float64
13   cap          238 non-null    int64
14   maincity     238 non-null    int64
15   citynum      238 non-null    object
16   langoff_1    238 non-null    object
17   langoff_2    238 non-null    object
18   langoff_3    238 non-null    object
19   lang20_1     238 non-null    object
20   lang20_2     238 non-null    object
21   lang20_3     238 non-null    object
22   lang20_4     238 non-null    object
23   lang9_1      238 non-null    object
24   lang9_2      238 non-null    object
25   lang9_3      238 non-null    object
26   lang9_4      238 non-null    object
27   colonizer1   238 non-null    object
28   colonizer2   238 non-null    object
29   colonizer3   238 non-null    object
30   colonizer4   238 non-null    object
31   short_colonizer1 238 non-null    object
32   short_colonizer2 238 non-null    object
33   short_colonizer3 238 non-null    object

```

dtypes: float64(3), int64(5), object(26)

memory usage: 63.3+ KB

	iso2	iso3	cnum	country	pays	area	dis_in
count	238	238	238.000000	238	238	2.380000e+02	238.000000
unique	225	225	NaN	225	225	NaN	NaN
top	AU	AUS	NaN	Australia	Australie	NaN	NaN
freq	2	2	NaN	2	2	NaN	NaN
mean	NaN	NaN	436.298319	NaN	NaN	7.581392e+05	203.882930
std	NaN	NaN	256.734227	NaN	NaN	2.056226e+06	256.833910
min	NaN	NaN	4.000000	NaN	NaN	7.000000e+00	0.995130
25%	NaN	NaN	212.500000	NaN	NaN	9.551250e+03	36.745790
50%	NaN	NaN	432.000000	NaN	NaN	1.058540e+05	122.360900
75%	NaN	NaN	657.750000	NaN	NaN	5.285480e+05	275.007450

```
#Premières lignes
df_cepii_langue.head()
```

	iso2	iso3	cnum	country	pays	area	dis_int	landlock
0	AW	ABW	533	Aruba	Aruba	193	5.225315	
1	AF	AFG	4	Afghanistan	Afghanistan	652225	303.761400	
2	AO	AGO	24	Angola	Angola	1246700	419.966600	
3	AI	AIA	660	Anguilla	Anguilla	102	3.798690	
4	AL	ALB	8	Albania	Albanie	28748	63.773110	

```
#Dernières lignes
df_cepii_langue.tail()
```

	iso2	iso3	cnum	country	pays	area	dis_int	landlocke
233	ZA	ZAF	711	South Africa	Afrique du Sud	1219912	415.4302	
234	ZA	ZAF	711	South Africa	Afrique du Sud	1219912	415.4302	
235	ZR	ZAR	180	Congo (Democratic Republic of the)	Congo. Rép. dém. du	2345410	576.0275	
236	ZM	ZMB	894	Zambia	Zambie	752614	326.3022	
237	ZW	ZWE	716	Zimbabwe	Zimbabwe	390759	235.1193	

```
#Suppression des colonnes superflues
df_cepii_langue_c =df_cepii_langue.drop(columns=['iso2','country','
df_cepii_langue_c.info()
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 238 entries, 0 to 237
Data columns (total 7 columns):
#   Column          Non-Null Count  Dtype  
---  -
0   iso3             238 non-null   object 
1   cnum             238 non-null   int64  
2   pays            238 non-null   object 
3   continent       238 non-null   object 
4   langoff_1       238 non-null   object 
5   langoff_2       238 non-null   object 
6   langoff_3       238 non-null   object 
dtypes: int64(1), object(6)
memory usage: 13.1+ KB
```

✓ 2.9.3 - Mise en forme

```
#Mise en forme finale
```

```
df_cepii_langue_f = df_cepii_langue_c.rename(columns={'iso3':'Id pa
df_cepii_langue_f = df_cepii_langue_f.replace('.', '')
df_cepii_langue_f = df_cepii_langue_f.dropna()
df_cepii_langue_f
```

	Id pays	Code pays	Pays	Continent	langoff_1	langoff_2	langoff_3
0	ABW	533	Aruba	America	Dutch	Spanish	
1	AFG	4	Afghanistan	Asia	Persian		
2	AGO	24	Angola	Africa	Portuguese		
3	AIA	660	Anguilla	America	English		
4	ALB	8	Albanie	Europe	Albanian		
...	...	...	...	...	...	...	...
233	ZAF	711	Afrique du Sud	Africa	English		
234	ZAF	711	Afrique du Sud	Africa	English		
235	ZAR	180	Congo. Rép. dém. du	Africa	French		

```
#Caractéristiques
df_cepii_langue_f.info()
print("\n")
df_cepii_langue_f.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 238 entries, 0 to 237
Data columns (total 7 columns):
#   Column          Non-Null Count  Dtype
---  -
0   Id pays         238 non-null    object
1   Code pays       238 non-null    int64
2   Pays            238 non-null    object
3   Continent       238 non-null    object
4   langoff_1       238 non-null    object
5   langoff_2       238 non-null    object
6   langoff_3       238 non-null    object
dtypes: int64(1), object(6)
memory usage: 13.1+ KB
```

	Id pays	Code pays	Pays	Continent	langoff_1	langoff_2	langoff_3
count	238	238.000000	238	238	238	238	238
unique	225	NaN	225	6	69	20	20
top	AUS	NaN	Australie	Africa	English		
freq	2	NaN	2	61	70	180	180
mean	NaN	436.298319	NaN	NaN	NaN	NaN	NaN
std	NaN	256.734227	NaN	NaN	NaN	NaN	NaN
min	NaN	4.000000	NaN	NaN	NaN	NaN	NaN
25%	NaN	212.500000	NaN	NaN	NaN	NaN	NaN
50%	NaN	432.000000	NaN	NaN	NaN	NaN	NaN
75%	NaN	657.750000	NaN	NaN	NaN	NaN	NaN
max	NaN	664.000000	NaN	NaN	NaN	NaN	NaN

```
#Identifier les 'Id pays' en donblon
df_cepii_langue_f[df_cepii_langue_f['Id pays'].duplicated(keep=False)]
```

	Id pays	Code pays	Pays	Continent	langoff_1	langoff_2	langoff_3
12	AUS	36	Australie	Pacific	English		

13	AUS	36	Australie	Pacific	English		
18	BEN	204	Bénin	Africa	French		
19	BEN	204	Bénin	Africa	French		
29	BOL	68	Bolivie	America	Spanish	Quecha	Aymara
30	BOL	68	Bolivie	America	Spanish	Quecha	Aymara
31	BRA	76	Brésil	America	Portuguese		
32	BRA	76	Brésil	America	Portuguese		
38	CAN	124	Canada	America	English	French	
39	CAN	124	Canada	America	English	French	
44	CIV	384	Côte d'Ivoire	Africa	French		
45	CIV	384	Côte d'Ivoire	Africa	French		
58	DEU	276	Allemagne	Europe	German		
59	DEU	276	Allemagne	Europe	German		
110	KAZ	398	Kazakstan	Asia	Kazakh	Russian	
111	KAZ	398	Kazakstan	Asia	Kazakh	Russian	
153	NGA	566	Nigéria	Africa	English		
154	NGA	566	Nigéria	Africa	English		
212	TUR	792	Turquie	Europe	Turkish		
213	TUR	792	Turquie	Europe	Turkish		
216	TZA	834	Tanzanie	Africa	English	Swahili	
217	TZA	834	Tanzanie	Africa	English	Swahili	
221	USA	842	Etats-Unis d'Amérique	America	English		
222	USA	842	Etats-Unis	America	English		

```
#Supprimer les 'Id pays' en doublon
df_cepii_langue_f = df_cepii_langue_f.drop_duplicates(subset='Id pa
df_cepii_langue_f.info()
print("\n")
df_cepii_langue_f.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 225 entries, 0 to 237
Data columns (total 7 columns):
#   Column      Non-Null Count  Dtype
---  -
0   Id pays     225 non-null    object
1   Code pays   225 non-null    int64
2   Pays        225 non-null    object
3   Continent   225 non-null    object
4   langoff_1   225 non-null    object
5   langoff_2   225 non-null    object
6   langoff_3   225 non-null    object
dtypes: int64(1), object(6)
memory usage: 14.1+ KB
```

	Id pays	Code pays	Pays	Continent	langoff_1	langoff_2	langof
count	225	225.000000	225	225	225	225	
unique	225	NaN	225	6	69	20	
top	ABW	NaN	Aruba	Africa	English		
freq	1	NaN	1	56	64	171	
mean	NaN	437.902222	NaN	NaN	NaN	NaN	
std	NaN	254.179526	NaN	NaN	NaN	NaN	
min	NaN	4.000000	NaN	NaN	NaN	NaN	
25%	NaN	218.000000	NaN	NaN	NaN	NaN	
50%	NaN	440.000000	NaN	NaN	NaN	NaN	
75%	NaN	654.000000	NaN	NaN	NaN	NaN	
max	NaN	664.000000	NaN	NaN	NaN	NaN	

✓ Etape 3 - Dataframes intermédiaires

✓ 3.1 - Liaison FAO

```
#Clés
df_fao_dispo_f['Clé FA0'] = df_fao_dispo_f['Code pays'].astype(str)
df_fao_healthydiet_f['Clé FA0'] = df_fao_healthydiet_f['Code pays']
df_fao_PIB_f['Clé FA0'] = df_fao_PIB_f['Code pays'].astype(str) + '
df_fao_population_f['Clé FA0'] = df_fao_population_f['Code pays'].a
df_fao_stability_f['Clé FA0'] = df_fao_stability_f['Code pays'].ast
```

```
#Liaisons
df_1 = pd.merge(df_fao_healthydiet_f,df_fao_dispo_f[['Clé FA0','Dis
df_2 = pd.merge(df_1,df_fao_PIB_f[['Clé FA0','PIB/hab ($ PPA intern
df_3 = pd.merge(df_2, df_fao_population_f[['Clé FA0','Pop rurale (p
df_fao = pd.merge(df_3, df_fao_stability_f[['Clé FA0','Indice stabi
```



```
#Suppression 'Clé_fao'
df_fao = df_fao.drop(columns=['Clé FA0'])
df_fao = df_fao.dropna()
df_fao
```

	Pays	Code pays	Année	Pop sans moyen de se nourrir sainement (en million)	Dispo viande volaille (kg/personne/an)	Import viande volaille (1000 t)	Prod vc (1
0	Afrique du Sud	710	2017	35.0	36.71	514.0	
1	Afrique du Sud	710	2018	35.3	38.02	515.0	
2	Afrique du Sud	710	2019	35.9	37.72	488.0	
3	Afrique du Sud	710	2020	37.4	37.32	425.0	
4	Afrique du Sud	710	2021	37.6	36.41	372.0	
...	...	...	...	...	...	...	
1369	Éthiopie	231	2018	65.8	0.62	0.0	
1370	Éthiopie	231	2019	66.4	0.48	1.0	
1371	Éthiopie	231	2020	67.9	0.54	0.0	
1372	Éthiopie	231	2021	70.8	0.40	1.0	
1373	Éthiopie	231	2022	71.6	0.45	0.0	

```
#Caractéristiques
df_fao.info()
print("\n")
df_fao.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 883 entries, 0 to 1373
Data columns (total 13 columns):
#    Column                                     Non-Null C
---  -
0    Pays                                     883 non-nu
1    Code pays                             883 non-nu
-
```

```

2   Année 883 non-nu
3   Pop sans moyen de se nourrir sainement (en million) 883 non-nu
4   Dispo viande volaille (kg/personne/an) 883 non-nu
5   Import viande volaille (1000 t) 883 non-nu
6   Production viande volaille (1000 t) 883 non-nu
7   Dispo intérieure viande volaille (1000 t) 883 non-nu
8   PIB/hab ($ PPA internationaux constants de 2021) 883 non-nu
9   Pop rurale (pour 1000) 883 non-nu
10  Pop urbaine (pour 1000) 883 non-nu
11  Pop totale (pour 1000) 883 non-nu
12  Indice stabilité politique 883 non-nu
dtypes: float64(10), int64(2), object(1)
memory usage: 96.6+ KB

```

	Pays	Code pays	Année	Pop sans moyen de se nourrir sainement (en million)	Dispo viande volaille (kg/personne/an)	v
count	883	883.000000	883.000000	883.000000	883.000000	883
unique	149	NaN	NaN	NaN	NaN	
top	Afrique du Sud	NaN	NaN	NaN	NaN	
freq	6	NaN	NaN	NaN	NaN	
mean	NaN	430.045300	2019.515289	15.55957	22.909751	9
std	NaN	248.201609	1.706511	65.15735	17.448917	17
min	NaN	8.000000	2017.000000	0.00000	0.400000	
25%	NaN	216.000000	2018.000000	0.20000	8.135000	
50%	NaN	422.000000	2020.000000	1.50000	20.370000	2
75%	NaN	646.000000	2021.000000	8.90000	32.310000	9
max	NaN	894.000000	2022.000000	804.90000	95.470000	119

✓ 3.2 - Liaison WBG

```
#Clés
```

```
df_wbg_index_f['Clé WBG'] = df_wbg_index_f['Id pays'] + '-' + df_wbg_index_f['Année']
df_wbg_temperature_f['Clé WBG'] = df_wbg_temperature_f['Id pays'] + '-' + df_wbg_temperature_f['Année']
```

```
#Liaisons
```

```
df_wbg = pd.merge(df_wbg_temperature_f, df_wbg_index_f[['Clé WBG', 'Id pays']], on='Clé WBG', how='left')
```

```
#Suppression 'Clé wbg'
```

```
df_wbg = df_wbg.drop(columns=['Clé WBG'])
```

```
df_wbg = df_wbg.dropna()
```

```
df_wbg
```

	Id pays	Pays	Année	Temp surface terrestre (°C)	Taux pop accès électricité	Indice perf log	c
0	AFG	Afghanistan	2010	29.6243831	42.7	2.24	-1.64539
2	AFG	Afghanistan	2012	27.3746873	69.1	2.3	-1.43037
4	AFG	Afghanistan	2014	28.6281367	89.5	2.069573	-1.36493
6	AFG	Afghanistan	2016	30.6263973	97.7	2.141282	-1.54022
8	AFG	Afghanistan	2018	30.1259055	93.4	1.95	-1.50287
...	...	...	...	...	...	...	...
2280	ZMB	Zambia	2018	30.5621355	40.2	2.53	-0.678888
2286	ZWE	Zimbabwe	2012	32.8124978	44	2.55	-1.38180
2288	ZWE	Zimbabwe	2014	31.6870377	32.3	2.33928	-1.40475
2290	ZWE	Zimbabwe	2016	33.1871179	42.5	2.082408	-1.28866

```
#Conservation de l'année 2018 uniquement
```

```
df_wbg_2018 = df_wbg[df_wbg['Année'] == '2018'].reset_index(drop=True)
df_wbg_2018 = df_wbg_2018.rename(columns={'Temp surface terrestre (°C)' : 'Temp surface terrestre 2018 (°C)'})
df_wbg_2018 = df_wbg_2018.drop(columns=['Année'])
df_wbg_2018
```

	Id pays	Pays	Temp surface terrestre 2018 (°C)	Taux pop accès électricité 2018	Indice perf log 2018	Indice corruption 2018
0	AFG	Afghanistan	30.1259055	93.4	1.95	-1.5028759241104
1	AGO	Angola	30.0623632	45.3	2.05	-1.1994838714599
2	ALB	Albania	19.6873912	100	2.66	-0.54601889848709
3	ARE	United Arab Emirates	43.6890475	100	3.96	1.1170514822006
4	ARG	Argentina	24.8753089	100	2.89	-0.099273927509784
...	...	...	...	...	...	...
152	VNM	Viet Nam	27.8129576	100	3.27	-0.51184302568435
153	YEM	Yemen, Rep.	40.3114994	62	2.27	-1.6583919525146
154	ZAF	South Africa	30.3751191	84.7	3.38	-0.13679742813110
155	ZMB	Zambia	30.5621355	40.2	2.53	-0.67888844013214

```
#Caractéristiques
df_wbg.info()
print("\n")
df_wbg.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 774 entries, 0 to 2292
Data columns (total 8 columns):
#   Column                                     Non-Null Count  Dtype
---  -
0   Id pays                                   774 non-null    object
1   Pays                                     774 non-null    object
2   Année                                    774 non-null    object
3   Temp surface terrestre (°C)             774 non-null    object
4   Taux pop accès électricité              774 non-null    object
5   Indice perf log                          774 non-null    object
6   Indice corruption                       774 non-null    object
7   Indice état de droit                    774 non-null    object
dtypes: object(8)
memory usage: 70.6+ KB
```

	Id pays	Pays	Année	Temp surface terrestre (°C)	Taux pop accès électricité	Indice perf log	co
count	774	774	774	774	774	774	
unique	164	164	5	774	294	494	

✓ 3.3 - Liaison CEPII

```
#Liaisons
df_cepil = pd.merge(df_cepil_distance_f, df_cepil_langue_f[['Id pay
```

```
#Suppression lignes NA
df_cepii = df_cepii.dropna()
df_cepii
```

	Id pays	Distance avec la France (km)	Code pays	Pays	Continent	langoff_1	langoff_2
0	ABW	7716,752	533	Aruba	America	Dutch	Spanish
1	AFG	5500,665	4	Afghanistan	Asia	Persian	
2	AGO	6384,805	24	Angola	Africa	Portuguese	
3	AIA	6743,427	660	Anguilla	America	English	
4	ALB	1499,451	8	Albanie	Europe	Albanian	
...	...	...	...	...	...	...	...
219	YUG	1429,045	891	Serbie et Monténégro (ex- Yougoslavie)	Europe	Serbo- Croatian	
220	ZAF	8769,679	711	Afrique du Sud	Africa	English	

```
#Caractéristiques
df_cepii.info()
print("\n")
df_cepii.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 224 entries, 0 to 223
Data columns (total 8 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   Id pays                               224 non-null    object
1   Distance avec la France (km)         224 non-null    object
2   Code pays                             224 non-null    int64
3   Pays                                  224 non-null    object
4   Continent                             224 non-null    object
5   langoff_1                             224 non-null    object
6   langoff_2                             224 non-null    object
7   langoff_3                             224 non-null    object
dtypes: int64(1), object(7)
memory usage: 14.1+ KB
```

	Id pays	Distance avec la France (km)	Code pays	Pays	Continent	langoff_1	langoff_2
count	224	224	224.000000	224	224	224	224
unique	224	220	NaN	224	5	69	69
top	ABW	.	NaN	Aruba	Africa	English	English
freq	1	5	NaN	1	56	64	64
mean	NaN	NaN	438.696429	NaN	NaN	NaN	NaN
std	NaN	NaN	254.468842	NaN	NaN	NaN	NaN
min	NaN	NaN	4.000000	NaN	NaN	NaN	NaN
25%	NaN	NaN	217.000000	NaN	NaN	NaN	NaN
50%	NaN	NaN	441.000000	NaN	NaN	NaN	NaN

✓ Etape 4 - Création des variables calculées

4.1 - FAO : Taux de croissance annuel moyen du PIB entre 2017 et 2022

```
#Tableau temporaire
df_pivot_pib = df_fao.pivot_table(index='Pays',columns='Année',valu

#Calcul du TCAM entre 2017 et 2022 : ((V_finale / V_initiale)^(1/n)
n = 7
df_pivot_pib['TCAM PIB 2017-2022'] = ((df_pivot_pib[2022] / df_pivc

#Ajout à df_fao
df_fao = pd.merge(df_fao,df_pivot_pib[['TCAM PIB 2017-2022']], on='
df_fao
```

	Pays	Code pays	Année	Pop sans moyen de se nourrir sainement (en million)	Dispo viande volaille (kg/personne/an)	Import viande volaille (1000 t)	Produ v vol (10
0	Afrique du Sud	710	2017	35.0	36.71	514.0	
1	Afrique du Sud	710	2018	35.3	38.02	515.0	
2	Afrique du Sud	710	2019	35.9	37.72	488.0	
3	Afrique du Sud	710	2020	37.4	37.32	425.0	
4	Afrique du Sud	710	2021	37.6	36.41	372.0	
...	...	...	...	...	...	...	
878	Éthiopie	231	2018	65.8	0.62	0.0	
879	Éthiopie	231	2019	66.4	0.48	1.0	
880	Éthiopie	231	2020	67.9	0.54	0.0	
881	Éthiopie	231	2021	70.8	0.40	1.0	
882	Éthiopie	231	2022	71.6	0.45	0.0	

883 rows x 14 columns

4.2 - FAO : Taux de croissance annuel moyen de la population entre 2017 et 2022

```
#Tableau temporaire
df_pivot_pop = df_fao.pivot_table(index='Pays',columns='Année',valu

#Calcul du TCAM entre 2017 et 2022 : ((V_finale / V_initiale)^(1/n)
n = 7
df_pivot_pop['TCAM Population 2017-2022'] = ((df_pivot_pop[2022] /

#Ajout à df_fao
df_fao = pd.merge(df_fao,df_pivot_pop[['TCAM Population 2017-2022']]
df_fao
```

	Pays	Code pays	Année	Pop sans moyen de se nourrir sainement (en million)	Dispo viande volaille (kg/personne/an)	Import viande volaille (1000 t)	Produit viande volaille (1000 t)
0	Afrique du Sud	710	2017	35.0	36.71	514.0	
1	Afrique du Sud	710	2018	35.3	38.02	515.0	
2	Afrique du Sud	710	2019	35.9	37.72	488.0	
3	Afrique du Sud	710	2020	37.4	37.32	425.0	
4	Afrique du Sud	710	2021	37.6	36.41	372.0	
...	...	...	...	...	...	...	...
878	Éthiopie	231	2018	65.8	0.62	0.0	
879	Éthiopie	231	2019	66.4	0.48	1.0	
880	Éthiopie	231	2020	67.9	0.54	0.0	
881	Éthiopie	231	2021	70.8	0.40	1.0	
882	Éthiopie	231	2022	71.6	0.45	0.0	

883 rows x 15 columns

✓ 4.3 - FAO : Taux d'urbanisation annuel

```
df_fao['Taux urbanisation annuel'] = (df_fao['Pop urbaine (pour 1000)'] / df_fao['Pop rurale (pour 1000)']) * 100
df_fao = df_fao.drop(columns=['Pop urbaine (pour 1000)', 'Pop rurale (pour 1000)'])
df_fao
```

	Pays	Code pays	Année	Pop sans moyen de se nourrir sainement (en million)	Dispo viande volaille (kg/personne/an)	Import viande volaille (1000 t)	Produit viande volaille (1000 t)
0	Afrique du Sud	710	2017	35.0	36.71	514.0	
1	Afrique du Sud	710	2018	35.3	38.02	515.0	
2	Afrique du Sud	710	2019	35.9	37.72	488.0	
3	Afrique du Sud	710	2020	37.4	37.32	425.0	
4	Afrique du Sud	710	2021	37.6	36.41	372.0	
...	...	...	...	...	...	...	...
878	Éthiopie	231	2018	65.8	0.62	0.0	
879	Éthiopie	231	2019	66.4	0.48	1.0	
880	Éthiopie	231	2020	67.9	0.54	0.0	
881	Éthiopie	231	2021	70.8	0.40	1.0	
882	Éthiopie	231	2022	71.6	0.45	0.0	

883 rows x 14 columns

✓ 4.4 - FAO : Taux d'autosuffisance

```
df_fao['Taux autosuffisance'] = (df_fao['Production viande volaille'] / df_fao['Production viande volaille (1000 t)'] * 100)
df_fao
```

	Pays	Code pays	Année	Pop sans moyen de se nourrir sainement (en million)	Dispo viande volaille (kg/personne/an)	Import viande volaille (1000 t)	PIB/t inter cor
0	Afrique du Sud	710	2017	35.0	36.71	514.0	
1	Afrique du Sud	710	2018	35.3	38.02	515.0	
2	Afrique du Sud	710	2019	35.9	37.72	488.0	
3	Afrique du Sud	710	2020	37.4	37.32	425.0	
4	Afrique du Sud	710	2021	37.6	36.41	372.0	
...	...	...	...	...	...	...	
878	Éthiopie	231	2018	65.8	0.62	0.0	
879	Éthiopie	231	2019	66.4	0.48	1.0	
880	Éthiopie	231	2020	67.9	0.54	0.0	
881	Éthiopie	231	2021	70.8	0.40	1.0	
882	Éthiopie	231	2022	71.6	0.45	0.0	

883 rows × 13 columns

✓ 4.5 - CEPII : Score langue

```
#Création d'une fonction personnalisée à appliquer à chaque ligne
def score_langue(row):
#Création d'une liste des langues pour par ligne
    langues = [str(row['langoff_1']).lower(),
               str(row['langoff_2']).lower(),
               str(row['langoff_3']).lower()]

    # Condition 1 : français présent
    if any("français" in l or "french" in l for l in langues):
        return 2
    # Condition 2 : anglais présent (et donc pas français d'après l
    elif any("anglais" in l or "english" in l for l in langues):
        return 1
    # Condition 3 : Reste
    else:
        return 0

# Application de la fonction à df_fao
df_cepii['Score Langue'] = df_cepii.apply(score_langue, axis=1)
df_cepii
```

	Id pays	Distance avec la France (km)	Code pays	Pays	Continent	langoff_1	langoff_2
0	ABW	7716,752	533	Aruba	America	Dutch	Spanish
1	AFG	5500,665	4	Afghanistan	Asia	Persian	
2	AGO	6384,805	24	Angola	Africa	Portuguese	
3	AIA	6743,427	660	Anguilla	America	English	
4	ALB	1499,451	8	Albanie	Europe	Albanian	
...	...	...	...	...	...	...	...
219	YUG	1429,045	891	Serbie et Monténégro (ex- Yougoslavie)	Europe	Serbo- Croatian	
220	ZAF	8769,679	711	Afrique du Sud	Africa	English	

✓ Etape 5 - Dataframe final

✓ 5.1 - Finalisation de df_fao

```
#Conservation uniquement de l'année 2022 et suppression des lignes
df_fao_2022 = df_fao[df_fao['Année'] == 2022].reset_index(drop=True)
df_fao_2022 = df_fao_2022.rename(columns={'Pop sans moyen de se nourrir': 'Pop sans moyen de se nourrir sainement (en million) en 2022',
                                           'Dispo viande volaille (kg/personne/an) en 2022': 'Dispo viande volaille (kg/personne/an) en 2022',
                                           'Import viande volaille (1000 t) en 2022': 'Import viande volaille (1000 t) en 2022',
                                           'PIB/hab ($ PPA international) en 2022': 'PIB/hab ($ PPA international) en 2022',
                                           'Pop totale (pour 1000)': 'Pop totale (pour 1000)',
                                           'Indice stabilité politique': 'Indice stabilité politique',
                                           'Taux urbanisation annuel': 'Taux urbanisation annuel',
                                           'Taux autosuffisance': 'Taux autosuffisance'})

df_fao_2022 = df_fao_2022.dropna()
df_fao_2022
```

	Pays	Code pays	Année	Pop sans moyen de se nourrir sainement (en million) en 2022	Dispo viande volaille (kg/personne/an) en 2022	Import viande volaille (1000 t) en 2022	PIB/hab (\$ PPA international) en 2022
0	Afrique du Sud	710	2022	38.1	35.47	304.0	11000.0
1	Albanie	8	2022	0.3	22.68	47.0	1000.0
2	Algérie	12	2022	9.3	9.71	0.0	1000.0
3	Allemagne	276	2022	1.7	16.63	789.0	1000.0
4	Angola	24	2022	25.1	10.46	316.0	1000.0
...	...	...	...	...	...	...	...
144	Égypte	818	2022	49.6	17.90	20.0	1000.0
145	Émirats arabes unis	784	2022	0.2	47.53	638.0	1000.0
146	Équateur	218	2022	4.6	29.10	1.0	1000.0
147	États-Unis d'Amérique	840	2022	16.2	53.75	191.0	1000.0
148	Éthiopie	231	2022	71.6	0.45	0.0	1000.0

145 rows x 13 columns

```
#Suppression de la ligne France
df_fao_2022 = df_fao_2022[df_fao_2022['Pays'] != 'France']
```

✓ 5.2 - Liaison df_fao avec df_cepii

```
#Liaisons et identification des erreurs
df_f1 = pd.merge(df_fao_2022,df_cepii[['Code pays','Distance avec l
df_f1.loc[df_f1['Distance avec la France (km)'].isnull()]
```

	Pays	Code pays	Année	Pop sans moyen de se nourrir sainement (en million) en 2022	Dispo viande volaille (kg/personne/an) en 2022	Import viande volaille (1000 t) en 2022	PI in 2
0	Afrique du Sud	710	2022	38.1	35.47	304.0	
14	Belgique	56	2022	0.1	16.30	309.0	
55	Inde	356	2022	672.5	3.53	0.0	
62	Italie	380	2022	4.0	20.25	142.0	
85	Monténégro	499	2022	0.1	21.67	11.0	
92	Norvège	578	2022	0.1	21.36	4.0	
119	Serbie	688	2022	0.6	12.18	23.0	
125	Suisse	756	2022	0.1	17.90	49.0	
142	États-Unis d'Amérique	840	2022	16.2	53.75	191.0	

```
#Correction des clés
```

```
df_cepii.loc[df_cepii['Pays'] == 'Inde', 'Code pays'] = 356
df_cepii.loc[df_cepii['Pays'] == "Etats-Unis d'Amérique", 'Code pay
df_cepii.loc[df_cepii['Pays'] == 'Afrique du Sud', 'Code pays'] = 7
df_cepii.loc[df_cepii['Pays'] == 'Italie', 'Code pays'] = 380
df_cepii.loc[df_cepii['Pays'] == 'Belgique et Luxembourg', 'Code pa
df_cepii.loc[df_cepii['Pays'] == 'Suisse', 'Code pays'] = 756
df_cepii.loc[df_cepii['Pays'] == 'Serbie et Monténégro (ex-Yougosla
df_cepii.loc[df_cepii['Pays'] == 'Norvège', 'Code pays'] = 578
df_fao_2022.loc[df_fao_2022['Pays'] == 'Monténégro', 'Code pays'] =
```



```
#Liaison finale
```

```
df_f1 = pd.merge(df_fao_2022,df_cepii[['Id pays','Code pays','Conti
df_f1
```

	Pays	Code pays	Année	Pop sans moyen de se nourrir sainement (en million) en 2022	Dispo viande volaille (kg/personne/an) en 2022	Import viande volaille (1000 t) en 2022	PIB in (20
0	Afrique du Sud	710	2022	38.1	35.47	304.0	
1	Albanie	8	2022	0.3	22.68	47.0	
2	Algérie	12	2022	9.3	9.71	0.0	
3	Allemagne	276	2022	1.7	16.63	789.0	
4	Angola	24	2022	25.1	10.46	316.0	
...	...	...	...	...	...	...	
139	Égypte	818	2022	49.6	17.90	20.0	
140	Émirats arabes unis	784	2022	0.2	47.53	638.0	
141	Équateur	218	2022	4.6	29.10	1.0	
142	États-Unis d'Amérique	840	2022	16.2	53.75	191.0	
143	Éthiopie	231	2022	71.6	0.45	0.0	

144 rows x 17 columns

```
#Caractéristiques
```

```
df_f1.info()
```

```
print("\n")
```

```
df_f1.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
```

```
RangeIndex: 144 entries, 0 to 143
```

```
Data columns (total 17 columns):
```

```
#    Column
```

```
---
```

```
No
```

```
--
```

```

0    Pays                                                    14
1    Code pays                                              14
2    Année                                                  14
3    Pop sans moyen de se nourrir sainement (en million) en 2022  14
4    Dispo viande volaille (kg/personne/an) en 2022          14
5    Import viande volaille (1000 t) en 2022                14
6    PIB/hab ($ PPA internationaux constants de 2021) en 2022  14
7    Pop totale (pour 1000) en 2022                          14
8    Indice stabilité politique en 2022                      14
9    TCAM PIB 2017-2022                                      14
10   TCAM Population 2017-2022                               14
11   Taux urbanisation 2022                                  14
12   Taux autosuffisance 2022                                14
13   Id pays                                                  14
14   Continent                                                14
15   Distance avec la France (km)                            14
16   Score Langue                                             14
dtypes: float64(10), int64(3), object(4)
memory usage: 19.3+ KB

```

	Pays	Code pays	Année	Pop sans moyen de se nourrir sainement (en million) en 2022	Dispo viande volaille (kg/personne/an) en 2022	Impo vian volail (1000 en 20
count	144	144.000000	144.0	144.000000	144.000000	144.0000
unique	144	NaN	NaN	NaN	NaN	N
top	Afrique du Sud	NaN	NaN	NaN	NaN	N
freq	1	NaN	NaN	NaN	NaN	N
mean	NaN	433.229167	2022.0	15.649306	24.063403	90.6597
std	NaN	249.534216	0.0	60.805216	17.975380	180.7056
min	NaN	8.000000	2022.0	0.000000	0.450000	0.0000
25%	NaN	217.000000	2022.0	0.200000	9.652500	4.0000
50%	NaN	424.000000	2022.0	1.450000	21.305000	22.0000
75%	NaN	659.750000	2022.0	10.050000	34.382500	91.5000
max	NaN	894.000000	2022.0	672.500000	95.470000	1158.0000

5-3 - Liaison df_f1 avec df_wbg

df_wbg_2018

	Id pays	Pays	Temp surface terrestre 2018 (°C)	Taux pop accès électricité 2018	Indice perf log 2018	Indic corruption 201
0	AFG	Afghanistan	30.1259055	93.4	1.95	-1.5028759241104
1	AGO	Angola	30.0623632	45.3	2.05	-1.1994838714599
2	ALB	Albania	19.6873912	100	2.66	-0.54601889848709
3	ARE	United Arab Emirates	43.6890475	100	3.96	1.1170514822006
4	ARG	Argentina	24.8753089	100	2.89	-0.099273927509784
...	...	...	...	...	...	...
152	VNM	Viet Nam	27.8129576	100	3.27	-0.51184302568435
153	YEM	Yemen, Rep.	40.3114994	62	2.27	-1.6583919525146
154	ZAF	South Africa	30.3751191	84.7	3.38	-0.13679742813110
155	ZMB	Zambia	30.5621355	40.2	2.53	-0.67888844013214

```
#Correction de certains codes
```

```
df_f1.loc[df_f1['Pays'] == 'République démocratique du Congo', 'Id pays'] = 'ROU'
df_f1.loc[df_f1['Pays'] == 'Roumanie', 'Id pays'] = 'ROU'
df_f1.loc[df_f1['Pays'] == 'Serbie', 'Id pays'] = 'SRB'
df_f1.loc[df_f1['Pays'] == 'Monténégro', 'Id pays'] = 'MNE'
```

```
#Liaisons
```

```
df_f2 = pd.merge(df_f1, df_wbg_2018[['Id pays', 'Temp surface terrestre']], on='Id pays'
df_f2 = df_f2.dropna()
df_f2
```

	Pays	Code pays	Année	Pop sans moyen de se nourrir sainement (en million) en 2022	Dispo viande volaille (kg/personne/an) en 2022	Import viande volaille (1000 t) en 2022	PIB in 20
0	Afrique du Sud	710	2022	38.1	35.47	304.0	
1	Albanie	8	2022	0.3	22.68	47.0	
2	Algérie	12	2022	9.3	9.71	0.0	
3	Allemagne	276	2022	1.7	16.63	789.0	
4	Angola	24	2022	25.1	10.46	316.0	
...	...	...	...	...	...	...	
138	Zimbabwe	716	2022	0.0	7.69	5.0	
139	Égypte	818	2022	49.6	17.90	20.0	
140	Émirats arabes unis	784	2022	0.2	47.53	638.0	
141	Équateur	218	2022	4.6	29.10	1.0	
142	États-Unis d'Amérique	840	2022	16.2	53.75	191.0	

125 rows x 22 columns

```
#Caractéristiques
```

```
df_f2.info()
```

```
print("\n")
df_f2.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
Index: 125 entries, 0 to 142
Data columns (total 22 columns):
#   Column                                                                 No
---  ---
0    Pays                                                                 12
1    Code pays                                                            12
2    Année                                                                12
3    Pop sans moyen de se nourrir sainement (en million) en 2022      12
4    Dispo viande volaille (kg/personne/an) en 2022                    12
5    Import viande volaille (1000 t) en 2022                           12
6    PIB/hab ($ PPA internationaux constants de 2021) en 2022          12
7    Pop totale (pour 1000) en 2022                                     12
8    Indice stabilité politique en 2022                                 12
9    TCAM PIB 2017-2022                                                  12
10   TCAM Population 2017-2022                                           12
11   Taux urbanisation 2022                                              12
12   Taux autosuffisance 2022                                            12
13   Id pays                                                             12
14   Continent                                                           12
15   Distance avec la France (km)                                       12
16   Score Langue                                                        12
17   Temp surface terrestre 2018 (°C)                                   12
18   Taux pop accès électricité 2018                                    12
19   Indice perf log 2018                                                12
20   Indice corruption 2018                                              12
21   Indice état de droit 2018                                           12
dtypes: float64(10), int64(3), object(9)
memory usage: 22.5+ KB
```

	Pays	Code pays	Année	Pop sans moyen de se nourrir sainement (en million) en 2022	Dispo viande volaille (kg/personne/an) en 2022	Import viande volaille (1000 en 2022)
count	125	125.000000	125.0	125.000000	125.000000	125.000000
unique	125	NaN	NaN	NaN	NaN	NaN
top	Afrique du Sud	NaN	NaN	NaN	NaN	NaN
freq	1	NaN	NaN	NaN	NaN	NaN
mean	NaN	431.424000	2022.0	16.698400	22.748800	98.952000

std	NaN	246.252436	0.0	64.800911	16.019901	190.7020
min	NaN	8.000000	2022.0	0.000000	0.840000	0.0000
25%	NaN	218.000000	2022.0	0.300000	9.710000	4.0000
50%	NaN	418.000000	2022.0	1.700000	20.740000	24.0000
75%	NaN	643.000000	2022.0	10.200000	31.910000	98.0000
max	NaN	894.000000	2022.0	672.500000	70.860000	1158.0000

5.4 - Identification des outliers

```
df_num = df_f2.select_dtypes(include=[np.number])
```

```
mean = df_num.mean()
```

```
std = df_num.std()
```

```
z_scores = (df_num - mean) / std
```

```
seuil = 3
```

```
mask_outliers = (np.abs(z_scores) > seuil).any(axis=1)
```

```
outliers = df_f2[mask_outliers]
```

```
print(f"Nombre total de pays avec au moins une valeur aberrante (Z > 3) : {len(outliers)}")
```

```
outliers
```

```
Nombre total de pays avec au moins une valeur aberrante (Z > 3) : 11
```

	Pays	Code pays	Année	Pop sans moyen de se nourrir sainement (en million) en 2022	Dispo viande volaille (kg/personne/an) en 2022	Import viande volaille (1000 t) en 2022	P:
3	Allemagne	276	2022	1.7	16.63	789.0	
51	Guyana	328	2022	0.1	70.86	1.0	
55	Inde	356	2022	672.5	3.53	0.0	
59	Irlande	372	2022	0.0	29.99	110.0	
74	Luxembourg	442	2022	0.0	19.70	14.0	
83	Mexique	484	2022	28.4	38.49	1158.0	

Pays-Ras

100	Royaume des	528	2022	0.2	13.52	897.0
102	Pologne	616	2022	2.5	33.30	78.0
106	Royaume-Uni de Grande-Bretagne et d'Irlande du...	826	2022	1.7	35.62	947.0
108	République arabe syrienne	760	2022	12.3	5.14	22.0
131	Thaïlande	764	2022	12.9	10.72	2.0

```
#Identification des pays représentant 60% de la population et du tc
df_f2 = df_f2.sort_values(by='Pop totale (pour 1000) en 2022', asce
df_f2['Pop cumulée (pour 1000) en 2022'] = df_f2['Pop totale (pour
df_f2['Pop cumulée (%) en 2022'] = (df_f2['Pop cumulée (pour 1000)
df_60 = df_f2[df_f2['Pop cumulée (%) en 2022'] < 60]
df_60.shape
```

```
(35, 24)
```

Les 125 pays de l'échantillon représentent bien plus de 60% de la population mondiale.

✓ Etape 6 - Mise en forme du Dataframe final P11

✓ 6.1 - Nettoyage du dataframe final

```
#Caractéristiques du df_f2
df_f2.info()
print("\n")
df_f2.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 125 entries, 0 to 124
Data columns (total 24 columns):
#    Column
```

No

```

"      "
---  ---
0    Pays                                12
1    Code pays                          12
2    Année                              12
3    Pop sans moyen de se nourrir sainement (en million) en 2022  12
4    Dispo viande volaille (kg/personne/an) en 2022                12
5    Import viande volaille (1000 t) en 2022                       12
6    PIB/hab ($ PPA internationaux constants de 2021) en 2022      12
7    Pop totale (pour 1000) en 2022                                 12
8    Indice stabilité politique en 2022                             12
9    TCAM PIB 2017-2022                                             12
10   TCAM Population 2017-2022                                       12
11   Taux urbanisation 2022                                           12
12   Taux autosuffisance 2022                                         12
13   Id pays                                                           12
14   Continent                                                         12
15   Distance avec la France (km)                                     12
16   Score Langue                                                      12
17   Temp surface terrestre 2018 (°C)                                12
18   Taux pop accès électricité 2018                                  12
19   Indice perf log 2018                                             12
20   Indice corruption 2018                                           12
21   Indice état de droit 2018                                        12
22   Pop cumulée (pour 1000) en 2022                                  12
23   Pop cumulée (%) en 2022                                          12
dtypes: float64(12), int64(3), object(9)
memory usage: 23.6+ KB

```

	Pays	Code pays	Année	Pop sans moyen de se nourrir sainement (en million) en 2022	Dispo viande volaille (kg/personne/an) en 2022	Import viande volaille (1000 t en 2022)
count	125	125.000000	125.0	125.000000	125.000000	125.000000
unique	125	NaN	NaN	NaN	NaN	NaN
top	Inde	NaN	NaN	NaN	NaN	NaN
freq	1	NaN	NaN	NaN	NaN	NaN
mean	NaN	431.424000	2022.0	16.698400	22.748800	98.95200
std	NaN	246.252436	0.0	64.800911	16.019901	190.70209
min	NaN	8.000000	2022.0	0.000000	0.840000	0.00000
25%	NaN	218.000000	2022.0	0.300000	9.710000	4.00000
50%	NaN	418.000000	2022.0	1.700000	20.740000	24.00000


```
#Suppression des colonnes superflues
df_f3= df_f2.drop(columns=['Code pays','Année','Id pays','Pop cumul

#Convertir 'Distance avec la France (km)' en nombres en remplaçant
df_f3['Distance avec la France (km)'] = df_f3['Distance avec la Fra

#Convertir le type des autres variables devant être des nombres
df_f3['Temp surface terrestre 2018 (°C)'] = df_f3['Temp surface ter
df_f3['Taux pop accès électricité 2018'] = df_f3['Taux pop accès él
df_f3['Indice perf log 2018'] = df_f3['Indice perf log 2018'].astype
df_f3['Indice corruption 2018'] = df_f3['Indice corruption 2018'].a
df_f3['Indice état de droit 2018'] = df_f3['Indice état de droit 20
```

✓ 6.2 - Identification des outliers

```

#Identification
noms_pays = df_f3['Pays'].values
df_num = df_f3.select_dtypes(include=[np.number])

mean = df_num.mean()
std = df_num.std()

z_scores = (df_num - mean) / std

anomalies = []

for i in range(len(z_scores)):
    row = z_scores.iloc[i]
    for column, value in row.items():
        if abs(value) > 5:
            anomalies.append({
                'Pays': noms_pays[i],
                'Variable': column,
                'Valeur Brute': df_num.iloc[i][column],
                'Z-score': round(value, 2)
            })

df_anomalies_detail = pd.DataFrame(anomalies)

df_anomalies_detail.sort_values(by='Z-score', ascending=False)

```

	Pays	Variable	Valeur Brute	Z-score
0	Inde	Pop sans moyen de se nourrir sainement (en mil...	6.725000e+02	10.12
1	Inde	Pop totale (pour 1000) en 2022	1.425423e+06	10.09
3	Guyana	TCAM PIB 2017-2022	1.640193e+01	7.72

Nous conservons le Mexique car la variable 'Import viande volaille (1000 t) en 2022' est stratégique pour l'analyse business.

Nous supprimons l'Inde car elle aura une trop forte influence sur l'étude du marché et donc la fausser, de plus une variable 'Pop sans moyen de se nourrir sainement' trop élevée n'est pas un bon indicateur pour notre business.

Nous supprimons également le Guyana car la croissance exceptionnelle de son PIB est déconnecté du secteur alimentaire car il s'agit de l'exploitation pétrolière, cela fausserait notre analyse.

```
#Suppression des outliers
pays_a_supprimer = ['Inde', 'Guyana']
df_P11 = df_f3[~df_f3['Pays'].isin(pays_a_supprimer)]
df_P11.reset_index(drop=True, inplace=True)
```

✓ 6.3 - Finalisation et extraction du dataframe final

```
#Caractéristiques
df_P11.info()
print("\n")
df_P11.describe(include='all')
```

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 123 entries, 0 to 122
Data columns (total 19 columns):
#   Column                                                                 No
---  -
0   Pays                                                                 12
1   Pop sans moyen de se nourrir sainement (en million) en 2022      12
2   Dispo viande volaille (kg/personne/an) en 2022                  12
3   Import viande volaille (1000 t) en 2022                          12
4   PIB/hab ($ PPA internationaux constants de 2021) en 2022        12
5   Pop totale (pour 1000) en 2022                                    12
6   Indice stabilité politique en 2022                                12
7   TCAM PIB 2017-2022                                                12
8   TCAM Population 2017-2022                                         12
9   Taux urbanisation 2022                                            12
10  Taux autosuffisance 2022                                          12
11  Continent                                                         12
12  Distance avec la France (km)                                       12
13  Score Langue                                                       12
14  Temp surface terrestre 2018 (°C)                                   12
15  Taux pop accès électricité 2018                                    12
16  Indice perf log 2018                                              12
17  Indice corruption 2018                                             12
```

```
18 Indice état de droit 2018 12
dtypes: float64(16), int64(1), object(2)
memory usage: 18.4+ KB
```

	Pays	Pop sans moyen de se nourrir sainement (en million) en 2022	Dispo viande volaille (kg/personne/an) en 2022	Import viande volaille (1000 t) en 2022	PIB/hab (\$ international constant 2021) en \$
count	123	123.000000	123.000000	123.000000	123.00
unique	123	NaN	NaN	NaN	
top	États-Unis d'Amérique	NaN	NaN	NaN	
freq	1	NaN	NaN	NaN	
mean	NaN	11.501626	22.513902	100.552846	27325.30
std	NaN	26.707671	15.452779	191.838440	25570.93
min	NaN	0.000000	0.840000	0.000000	1386.00
25%	NaN	0.300000	9.845000	4.000000	6312.50
50%	NaN	1.700000	20.740000	25.000000	18459.00
75%	NaN	10.100000	31.610000	98.500000	42238.00
max	NaN	173.300000	70.330000	1158.000000	132574.00

```
#Suppression des accents
df_P11.loc[:, 'Pays'] = (df_P11['Pays']
                        .str.normalize('NFKD')
                        .str.encode('ascii', 'ignore')
                        .str.decode('utf-8'))
```

```
#Extraction en CSV
df_P11.to_csv("Data P11.csv", index=False)
```

